

Faculdade de Ciências e Tecnologias em Engenharia
Engenharia de *Software*

PREVISÃO E INTERPRETAÇÃO DOS INDICADORES DA BOLSA DE VALORES BRASILEIRA: UMA ABORDAGEM BASEADA EM LSTM E xAI

Felipe Aguiar Hansen

Orientador: Prof. Dr. Fabiano Araújo Soares

`fahansen98@gmail.com`

`fabianossoares@unb.br`

08 de dezembro de 2025

Introdução

Objetivos

Revisão Bibliográfica

Metodologia

Cronograma

Mercado de Ações

- ▶ Componente vital de qualquer economia, reflete as tendências e o desempenho macroeconômico de um país.
- ▶ IBOVESPA e o S&P 500 servem como termômetros do mercado, orientam investidores e analistas¹.
- ▶ Objetivo é antecipar seus movimentos para obter estratégias de investimento, lucros e diminuir riscos.
- ▶ Redes neurais têm se mostrado promissoras para modelar os padrões das séries temporais financeiras.
- ▶ Desafio, dada a natureza complexa, caótica, dinâmica e não-linear das séries temporais financeiras.².

¹João Victor Ribeiro Ferro et al. "Uma avaliação sistemática de técnicas de aprendizado de máquina baseadas em ensemble para previsão de índices do mercado de ações usando séries temporais financeiras". Em: (2024).

²David Michel Quirino Nelson. "Uso de redes neurais recorrentes para previsão de séries temporais financeiras". Em: (2017).

- ▶ Investimento em Aprendizado de Máquina (ML), como o *Deep Learning*, tem aberto novos e promissoras estudos para este desafio.³
- ▶ Modelos de *ML*, especialmente as redes neurais profundas, resultam em um problema de “caixa preta” (*black box*).
- ▶ Inteligência Artificial Explicável (xAI) busca desenvolver métodos para tornar as decisões compreensíveis.⁴

³Nelson, “Uso de redes neurais recorrentes para previsão de séries temporais financeiras”.

⁴Mohammadreza Ayatollahi e Seyed Mohammadbagher Jafari. “Explainable Artificial Intelligence (XAI) in Predicting Stock Market Crashes: A Case Study of the Tehran Stock Exchange”. Em: *ResearchGate Preprint* (jun. de 2025).

Contextualização do Problema

- ▶ Técnicas de previsão: ML clássico, *ensembles* e RNNs
- ▶ *LSTM* em alta para séries temporais financeiras.⁵
- ▶ Dificuldade: séries são voláteis e não-lineares; previsão exige lidar com dados históricos e variáveis exógenas.
- ▶ Mercado emergente (IBOVESPA) apresenta maior volatilidade, elevando risco e oportunidade.

⁵Nelson, “Uso de redes neurais recorrentes para previsão de séries temporais financeiras”.

- ▶ Escolha dos dados: OHLCV + indicadores técnicos; considerar fatores externos (ex.: dólar) para enriquecer a previsão.⁶
- ▶ Seleção da Ferramenta: *Python* é a comunidade mais ativa em IA (*TensorFlow* e o *PyTorch*).⁷
- ▶ Questão do estudo:

Como desenvolver um modelo de previsão para o mercado de ações baseado em redes neurais que não apenas alcance um desempenho preditivo satisfatório, mas que também ofereça interpretabilidade sobre os fatores que influenciam suas decisões?

⁶Ronaldo César Dametto. “Estudo da aplicação de redes neurais artificiais para predição de séries temporais financeiras”. Em: (2018).

⁷Coursera. *TensorFlow vs. Keras: What's the Difference?* Disponível em: <<https://www.coursera.org/articles/tensor-flow-vs-keras>>. Acesso em: 19 de nov. de 2025. 2025.

Impacto

1. Desenvolver um modelo de previsão robusto para o mercado de ações que combine as capacidades de Redes Neurais (LSTM) com a interpretabilidade da xAI.
2. Apresentar um *framework* prático para a integração de xAI no processo de *Deep Learning* aplicado à previsão de séries temporais financeiras.
3. Oferecer *insights* economicamente coerentes sobre quais fatores (e.g., cotações passadas, indicadores técnicos) realmente influenciam as decisões do modelo (via SHAP).

Desenvolver, treinar e validar um modelo de Rede Neural Recorrente LSTM para previsão de séries temporais do mercado de ações brasileiro, integrando uma ferramenta de xAI para obter explicações sobre as decisões do modelo de regressão.

- ▶ Adquirir e tratar o *dataset* da bolsa em formato estruturado.
- ▶ Construir a arquitetura LSTM e definir ferramenta/*framework*.
- ▶ Treinar, validar e avaliar o modelo.
- ▶ Gerar previsões e medir desempenho.
- ▶ Integrar SHAP para extrair explicações locais e globais.

- ▶ Bolsa de Valores
- ▶ Modelos de Previsão
- ▶ Abordagem e Fontes de Dados
- ▶ Ferramentas e *Frameworks*
- ▶ Emergência da xAI

- ▶ Ações: propriedade parcial de uma empresa.
- ▶ Índices de mercado: desempenho do conjunto das ações mais representativas (IBOVESPA e S&P 500).
- ▶ Variáveis de entrada padrão de negociação (OHLCV)

Tabela: Descrição das Variáveis de Negociação OHLCV

Variável	Descrição
<i>Open</i>	Preço do ativo no momento da abertura do pregão.
<i>High</i>	Preço máximo atingido pelo ativo durante o período de negociação.
<i>Low</i>	Preço mínimo atingido pelo ativo durante o período de negociação.
<i>Close</i>	Preço do ativo no momento do fechamento do pregão.
<i>Adj Close</i>	Preço de fechamento ajustado por eventos corporativos.
<i>Volume</i>	Quantidade total de ativos negociados no período.

Introdução à Bolsa de Valores



São Paulo - Delayed Quote • BRL

IBOVESPA (^BVSP) ☆ Follow

159,072.12 +712.12 +(0.45%)

At close: November 28 at 6:24:00 PM GMT-3

Dec 01, 2024 - Dec 01, 2025 Historical Prices Daily

Currency in BRL

Date	Open	High	Low	Close ⓘ	Adj Close ⓘ	Volume
Nov 28, 2025	158,358.00	159,689.00	158,078.00	159,072.00	159,072.00	8,017,000
Nov 27, 2025	158,554.00	158,864.00	158,167.00	158,292.00	158,292.00	3,121,400
Nov 26, 2025	155,915.00	158,714.00	155,914.00	158,555.00	158,555.00	8,596,500
Nov 25, 2025	155,278.00	156,373.00	154,821.00	155,910.00	155,910.00	6,929,400
Nov 24, 2025	154,769.00	155,832.00	154,529.00	155,278.00	155,278.00	9,277,600
Nov 21, 2025	155,381.00	155,387.00	153,571.00	154,770.00	154,770.00	7,848,000
Nov 19, 2025	156,522.00	156,522.00	155,212.00	155,381.00	155,381.00	8,815,200
Nov 18, 2025	156,990.00	157,040.00	155,834.00	156,522.00	156,522.00	8,723,000
Nov 17, 2025	157,742.00	157,901.00	156,568.00	156,993.00	156,993.00	8,419,200
Nov 14, 2025	157,162.00	158,366.00	156,656.00	157,739.00	157,739.00	7,977,300
Nov 13, 2025	157,633.00	158,319.00	156,509.00	157,162.00	157,162.00	10,560,800
Nov 12, 2025	157,749.00	158,134.00	156,560.00	157,633.00	157,633.00	11,226,600
Nov 11, 2025	155,257.00	158,467.00	155,252.00	157,749.00	157,749.00	12,876,000
Nov 10, 2025	154,061.00	155,601.00	154,058.00	155,257.00	155,257.00	7,751,600

Figura: Índices diários do IBOVESPA.⁸

⁸Yahoo Finance. *IBOVESPA (^BVSP)*. Disponível em:

<<https://finance.yahoo.com/quote/%5EBVSP/history/>>. Acesso em: 19 de nov. de 2025.
Felipe Aguiar Hansen | Previsão e Interpretação dos Indicadores da Bolsa de Valores Brasileira: Uma abordagem baseada em LSTM e xAI

- ▶ ML clássico: SVR, CART, MLP.
- ▶ *Deep Learning*: LSTM para dependências de longo prazo em séries financeiras.
- ▶ *Ensembles*: *Bagging/Boosting*.




Figura: Diferença entre *ensembles* de redes neurais e *ensembles* de árvores de decisão (Fonte:⁹)

⁹Super Data Science. *Modelos de Master Ensemble: Bagging vs Boosting em Machine Learning EXPLICADO*. Disponível em: <https://www.youtube.com/watch?v=ZFXD6lxm3nE&t=337s>. Acesso em: 01 de dez. de 2025. 2020.

Tabela: Escolha e Análise dos Modelos de Previsão

Artigo	Modelo Escolhido
Giacomel (2016)	<i>Ensembles</i> de Redes Neurais MLP
Dametto (2018)	<i>Ensemble</i> de Redes Neurais MLP, NARX, LSTM
Ferro et al. (2024)	<i>Ensembles</i> dos métodos MLP, SVR, CART, ARIMA
Nelson (2017)	Rede Neural LSTM
Ayatollahi e Jafari (2025)	<i>Ensemble</i> de Árvores de Decisão (<i>XGBoost</i>)
Ohana et al. (2021)	GBDT (<i>Gradient Boosting Decision Trees</i>)
Gupta et al. (2025)	Rede Neural LSTM

- ▶ Regressão: prever valor futuro do índice/preço
 - ▶ métricas de erro (MSE, RMSE, MAPE) e ajuste (R^2).
- ▶ Classificação: direção de movimento (alta/baixa) ou detecção de crises (*crashes*).
 - ▶ métricas de classificação: Acurácia;
 - ▶ cenários desbalanceados, usar Precisão, *Recall*, *F1-Score*.

- ▶ Mercados:
 - ▶ Desenvolvidos (S&P 500) têm menor volatilidade
 - ▶ Emergentes (IBOVESPA, TEPIX, HDFC) são mais instáveis e desafiadores.
- ▶ *Features*: OHLCV, indicadores técnicos e variáveis exógenas (ex.: câmbio).
- ▶ Granularidade e período



Figura: Volatilidade entre os mercados IBOVESPA (azul escuro) e S&P 500 (azul claro) desde 2000 (Fonte:¹⁰)

¹⁰Yahoo Finance. *IBOVESPA (^BVSP)*. Disponível em: <https://finance.yahoo.com/quote/%5EBVSP/chart/>. Acesso em: 01 de dez. de 2025. 2025.

Tabela: Objetivo de previsão e dados utilizados na literatura

Artigo	Objetivo de Previsão	Dados Utilizados
Giacomel (2016)	Classificação de movimento: alta/baixa	Ações mais negociadas dos mercados S&P 500 e BOVESPA
Dametto (2018)	Regressão	IBOVESPA e cotação do Dólar
Ferro et al. (2024)	Regressão	IBOVESPA e S&P 500
Nelson (2017)	Classificação de movimento: alta/baixa	Ativos de maior negociação do IBOVESPA
Ayatollahi e Jafari (2025)	Classificação de risco: <i>crash event</i>	TEPIX
Benhamou et al. (2021)	Classificação de risco: regime de crise/normal	S&P 500
Gupta et al. (2025)	Regressão	Ação HDFC Bank

- ▶ **Deep Learning:** *Keras/TensorFlow* para redes recorrentes.
- ▶ **ML Clássico e Ensembles:** *Scikit-learn* biblioteca de aprendizado de máquina de fácil implementação.
- ▶ **Boosting e Árvores:** *LightGBM* e *XGBoost*, otimizados para algoritmo GBDT.

- ▶ Desafio de entender como e por que um modelo chegou a um resultado específico.
- ▶ SHAP: explica a contribuição de cada variável para a previsão final.
- ▶ Crises e risco: SHAP em GBDT para identificar variáveis mais importantes¹¹.
- ▶ LSTM + SHAP: explica contribuição temporal de cada *time-step* na previsão de preço¹².

¹¹Jean Jacques Ohana et al. “Explainable AI (XAI) models applied to the multi-agent environment of financial markets”. Em: *International Workshop on Explainable, Transparent Autonomous Agents and Multi-Agent Systems*. Springer. 2021, pp. 189–207.

¹²Yashpal Gupta et al. “An Interpretable Framework for Stock Market Forecasting Using Long Short-Term Memory (LSTM) Networks with SHAP-Explainable AI (XAI) Method”. Em: *2025 6th International Conference on Data Intelligence and Cognitive Informatics (ICDICI)*. IEEE. 2025, pp. 539–546.




Figura: Fluxo de Projeto (Fonte: Autor(2025))

1. Aquisição dos dados:
 - ▶ IBOVESPA diário (03/01/2000 a 30/09/2025) via *Yahoo Finance*.
 - ▶ Variáveis OHLCV.
2. Pré-processamento:
 - ▶ Tratamento de Ruídos: interpolação ou *forward fill*.
 - ▶ Normalização *MinMax*.
 - ▶ *Sliding window* de 100 dias.
 - ▶ Divisão temporal: 65% treino / 35% teste.
3. Modelagem e Arquitetura:
 - ▶ Arquitetura *Stacked LSTM*.
 - ▶ Conexão sequencial de células LSTM.




Figura: Arquitetura da Rede Neural LSTM (Fonte:¹³)

¹³Nora Yehia. *Understanding Long Short Term Memory Networks*. Disponível em: <<https://mlarchive.com/deep-learning/understanding-long-short-term-memory-networks/>>. Acesso em: 01 de dez. de 2025. 2024.

4. Ferramentas de Implementação:

- ▶ *Keras* (API de alto nível) com *TensorFlow* (*backend*).

5. Avaliação e validação:

- ▶ Regressão
- ▶ Prever o preço futuro do fechamento do dia (*Adj Close price*)
- ▶ Métricas de erro: RMSE, R^2 *Score*.

6. Interpretabilidade:

- ▶ SHAP
- ▶ Contribuição Temporal dos *Time Steps*.
- ▶ Identificação de Variáveis Chave.

Cronograma de Atividades



Atividade	S1	S2	S3	S4	S5	S6	S7	S8	S9	S10	S11	S12	S13	S14	S15	S16
Aquisição de Dados	•	•														
Pré-processamento		•	•	•												
Modelagem				•	•	•										
Treinamento						•	•	•								
Avaliação e Validação								•	•	•	•	•				
Interpretabilidade (xAI)											•	•	•	•		
Escrita do Relatório					•	•	•	•	•	•	•	•	•	•		
Revisão e Ajustes														•	•	•

Obrigado pela atenção.