

Faculdade de Ciências e Tecnologias em Engenharia
Engenharia de *Software*

PREVISÃO E INTERPRETAÇÃO DE TENDÊNCIAS DO S&P500 COM MODELOS DE DEEP LEARNING E XAI

Felipe Aguiar Hansen

Orientador: Prof. Dr. Fabiano Araújo Soares

fahansen98@gmail.com

fabianossoares@unb.br

13 de julho de 2026

Introdução

Metodologia

Resultados

Conclusão

Mercado de Ações

- ▶ Reflete as tendências e o desempenho macroeconômico de um país.
- ▶ IBOVESPA e o S&P 500 servem como termômetros do mercado.
- ▶ Objetivo é antecipar seus movimentos.
- ▶ Nesse contexto as redes neurais vem se destacando.
- ▶ Desafio por conta da natureza das séries temporais financeiras.

- ▶ Recente investimento em Aprendizado de Máquina (ML), como o *Deep Learning*¹.
- ▶ Modelos de *ML* resultam em um problema de “caixa preta” (*black box*).
- ▶ Inteligência Artificial Explicável (xAI) busca desenvolver métodos para tornar as decisões compreensíveis.²

¹David Michel Quirino Nelson. “Uso de redes neurais recorrentes para previsão de séries temporais financeiras”. Em: (2017).

²Mohammadreza Ayatollahi e Seyed Mohammadbagher Jafari. “Explainable Artificial Intelligence (XAI) in Predicting Stock Market Crashes: A Case Study of the Tehran Stock Exchange”. Em: *ResearchGate Preprint* (jun. de 2025).

Contextualização do Problema

- ▶ Técnicas de previsão: ML clássico, *ensembles* e RNNs
- ▶ *LSTM* em alta para séries temporais financeiras.³
- ▶ Dificuldade: séries são voláteis e não-lineares.
- ▶ Novos modelos de previsões: xLSTM-TS e Transformer-TS

³Nelson, “Uso de redes neurais recorrentes para previsão de séries temporais financeiras”.

- ▶ Escolha dos dados e indicadores técnicos.
- ▶ Seleção da Ferramenta: *Python* é a comunidade mais ativa em IA⁴.
- ▶ Questão do estudo:

Como modelos baseados em LSTM, xLSTM e Transformer, integrados a técnicas de Inteligência Artificial Explicável (SHAP), podem melhorar a previsibilidade direcional e a interpretabilidade das decisões em séries temporais do índice S&P500?


⁴Coursera. *TensorFlow vs. Keras: What's the Difference?* Disponível em: <<https://www.coursera.org/articles/tensor-flow-vs-keras>>. Acesso em: 19 de nov. de 2025. 2025.

Impacto

1. Desenvolver um modelo de previsão robusto para o mercado de ações que combine as capacidades de Redes Neurais com a interpretabilidade da xAI.
2. Apresentar um *framework* prático para a integração de xAI no processo de *Deep Learning* aplicado à previsão de séries temporais financeiras.
3. Oferecer *insights* sobre quais fatores realmente influenciam as decisões do modelo (via SHAP).

Escopo do Projeto

Figura: Fluxo de Projeto



1. **Aquisição de Dados e Pré-processamento:** Coleta de preços históricos e tratamento.
2. ***Ablation Study (LSTM baseline)*:** Construção de *features* e teste de variantes.
3. **Modelos *SOTA*:** Previsões com os modelos *SOTA*: xLSTM-TS e Transformer-TS.
4. **Comparação de Desempenho dos Modelos:** Avaliação dos modelos de acordo com as métricas de classificação.
5. **Interpretabilidade xAI:** Aplicação do SHAP para identificar a importância de cada *timestep*.

Fonte e Período:

- ▶ S&P 500 diário: 03/01/2000 a 30/12/2024
- ▶ Variáveis OHLCV (*Open, High, Low, Close, Volume*)

Divisão Temporal:

- ▶ 84% treino (2000–2020): 5.282 dias
- ▶ 8% validação (2021–2022): 503 dias
- ▶ 8% teste (2023–2024): 503 dias

Tratamento de Ruído:

- ▶ Sem dados faltante e volume zero imputado pela mediana móvel

18 Features em 4 Categorias:

- ▶ *Log-retornos e defasagens (7 features)*
- ▶ *Tendência relativa (3 features)*
- ▶ *Volatilidade realizada (2 features)*
- ▶ *Volume e amplitude (6 features)*

Tabela: Variantes do Ablation Study de Pré-processamento

Variante	Input	Normalização	Motivação
A	<i>Close</i> bruto	<i>Z-score</i>	<i>Baseline</i> padrão da literatura. Ponto de referência mínimo.
B	<i>Close DWT</i>	<i>Z-score</i>	Aplica <i>DWT</i> antes de calcular as 18 <i>features</i> . Avalia se remover ruído melhora a aprendizagem.
C	<i>Log-retornos</i>	<i>Z-score</i>	Substitui <i>Close</i> pelo <i>log-retorno</i> diário. Avalia previsão em série estacionária.
D	<i>Log-ret. DWT</i>	<i>Z-score</i>	Aplica <i>DWT</i> nos <i>log-returns</i> . Combina estacionarização com <i>DWT</i> .
E	<i>Close</i> bruto	<i>Min-Max</i>	Normalização em intervalo [0,1]. Testa sensibilidade a valores extremos do treino.
F	<i>Close DWT</i>	<i>Min-Max</i>	Combina <i>DWT</i> com normalização <i>Min-Max</i> .

LSTM:

- ▶ Classificação Binária Direta - $P(\text{sobe}) = [0,1]$
- ▶ *Framework: Keras/TensorFlow 2.15*
- ▶ *Early stopping: paciência 10 épocas*

xLSTM-TS:

- ▶ Regressão com Direção Derivada
 - ▶ Para cada dia t , prever se o preço de $t + 1$ será maior (classe 1) ou menor (classe 0)
- ▶ *Framework: PyTorch 2.3.1*
- ▶ *Early stopping: paciência 40 épocas*
- ▶ Pré-processamento: *DWT causal + Min-Max*

Transformer-TS (Regressão com Direção Derivada):

- ▶ Regressão com Direção Derivada
 - ▶ Para cada dia t , prever se o preço de $t + 1$ será maior (classe 1) ou menor (classe 0)
- ▶ *Framework: PyTorch 2.3.1*
- ▶ *Early stopping: paciência 40 épocas*
- ▶ Pré-processamento: *DWT causal + Min-Max*

Métricas de Classificação:

- ▶ *MCC*: considera desequilíbrio de classes
- ▶ Acurácia, *F1-Score* e *AUC-ROC*: taxas de acerto

Métricas de Regressão (Modelos SOTA):

- ▶ *RMSE*, *MAPE* e R^2

Teste de *McNemar*:

- ▶ Verifica significância estatística

Aplicação do SHAP:

- ▶ Avaliação sobre 200 amostras do conjunto de teste
- ▶ *KernelExplainer* para LSTM (modelo *Keras*)
- ▶ *DeepExplainer* para modelos *SOTA*
- ▶ Atribui a cada *timestep* uma contribuição marginal para a previsão
- ▶ Importância global: média da magnitude $|SHAP|$ sobre todas as amostras

Foco da Análise:

- ▶ **Contribuição Temporal:** quais períodos da memória foram mais determinantes
- ▶ **Concentração da Atenção:** quantos *timesteps* explicam 90% da importância total

Tabela: Resultados Ablation Study da LSTM

<i>Var.</i>	<i>Acc Teste (%)</i>	<i>F1 (%)</i>	<i>MCC</i>	<i>AUC</i>	<i>McNemar p</i>
B	67,5	72,0	0,333	0,724	<0,001
F	64,7	70,2	0,273	0,687	0,004
D	62,3	70,8	0,211	0,671	0,017
A	61,5	69,6	0,195	0,652	0,049
C	61,5	69,6	0,195	0,652	0,049
E	56,5	72,2	0,000	0,512	1,000




Figura: Métricas de classificação direcional no teste por variante do ablation study




Figura: Curvas de perda de treino e validação por época para cada variante

Distribuição $P(\text{sobe})$ por Variante — Test Set




Figura: Distribuição de $P(\text{sobe})$ no conjunto de teste por variante e classe/valor real

Variante B: *Close DWT + Z-score*

Resultados — B




Figura: Resultados da variante B

xLSTM-TS		
Cat.	Métrica	Valor
Regressão	MAE	235,80 USD
	RMSE	375,40 USD
	MAPE	4,26%
	R^2	0,662
Direcional	Acurácia	75,8%
	Recall	76,6%
	F1	79,8%

Transformer-TS		
Cat.	Métrica	Valor
Regressão	MAE	541,81 USD
	RMSE	706,64 USD
	MAPE	10,19%
	R^2	-0,20
Direcional	Acurácia	75,6%
	Recall	86,9%
	F1	81,6%

Resultados Visuais xLSTM-TS




Figura: Resultados do xLSTM-TS no conjunto de teste (2023–2024)

Resultados Visuais Transformer-TS




Figura: Resultados do Transformer-TS no conjunto de teste (2023–2024)

Tabela: Comparativo de acurácia e F1 direcional dos três modelos no conjunto de teste

Modelo	Acc (%)	F1 (%)
LSTM Var. B	67,5	72,0
xLSTM-TS	75,8	79,8
Transformer-TS	75,6	81,6

Observações:

- ▶ R^2 inferior à persistência, mas classificação direcional é superior
- ▶ Métricas de regressão não são adequadas para julgar viabilidade operacional




Figura: Análise SHAP da LSTM (Variante B) sobre 200 amostras do conjunto de teste (2023–2024)




Figura: Análise SHAP do xLSTM-TS no conjunto de teste (2023–2024)




Figura: Análise SHAP do Transformer-TS no conjunto de teste (2023–2024)

1. **DWT é o pré-processamento mais impactante:** variantes com *DWT* superam consistentemente as sem *DWT* em *MCC*
2. **Sinal direcional consistente:** modelos *SOTA* obtiveram 75–76% de acurácia, contrastando com R^2 divergente
3. **Limitação do *Min-Max*:** saturação ao prever preços acima do máximo do treino (3.756 USD vs. 5.000–6.000 USD em 2023–2024)
4. **Janelas subutilizadas:** SHAP revela que modelos dependem predominantemente de curto prazo

- ▶ Variante B (*DWT + Z-score*) obteve melhor desempenho no *ablation study*
- ▶ Modelos *SOTA* superaram LSTM em acurácia direcional (+8 pontos percentuais)
- ▶ SHAP revelou concentração de atenção no passado imediato
- ▶ Janela de 150 dias não foi totalmente utilizada, indicando que as arquiteturas *SOTA* conseguem previsões mais corretas mesmo com contexto histórico

Limitações:

- ▶ Saturação da normalização *Min-Max*
- ▶ Janela de entrada fixa
- ▶ Escopo univariado dos modelos *SOTA*
- ▶ Dados de um único ativo e período
- ▶ Ausência de avaliação financeira
- ▶ Treino em regressão nos modelos *SOTA*

Trabalhos futuros:

- ▶ Modelos *SOTA* focados em classificação direcional com pré processamento e *inputs* validados do *Ablation Study*
- ▶ Avaliação de retorno financeiro
- ▶ Extensão para IBOVESPA

Obrigado pela atenção.