



Universidade de Brasília – UnB
Faculdade UnB Gama – FGA
Engenharia de Software

**Previsão e Interpretação dos Indicadores da
Bolsa de Valores Americana: Uma abordagem
baseada em LSTM e xAI**

Autor: Felipe Aguiar Hansen
Orientador: Dr. Fabiano Araújo Soares

Brasília, DF
2025



Felipe Aguiar Hansen

Previsão e Interpretação dos Indicadores da Bolsa de Valores Americana: Uma abordagem baseada em LSTM e xAI

Monografia submetida ao curso de graduação em Engenharia de Software da Universidade de Brasília, como requisito parcial para obtenção do Título de Bacharel em Engenharia de Software.

Universidade de Brasília – UnB

Faculdade UnB Gama – FGA

Orientador: Dr. Fabiano Araújo Soares

Brasília, DF

2025

Felipe Aguiar Hansen

Previsão e Interpretação dos Indicadores da Bolsa de Valores Americana: Uma abordagem baseada em LSTM e xAI/ Felipe Aguiar Hansen. – Brasília, DF, 2025-44 p. : il. (algumas color.) ; 30 cm.

Orientador: Dr. Fabiano Araújo Soares

Trabalho de Conclusão de Curso – Universidade de Brasília – UnB
Faculdade UnB Gama – FGA , 2025.

1. bolsa de valores. 2. previsão de séries temporais. I. Dr. Fabiano Araújo Soares. II. Universidade de Brasília. III. Faculdade UnB Gama. IV. Previsão e Interpretação dos Indicadores da Bolsa de Valores Americana: Uma abordagem baseada em LSTM e xAI

CDU 02:141:005.6

Felipe Aguiar Hansen

Previsão e Interpretação dos Indicadores da Bolsa de Valores Americana: Uma abordagem baseada em LSTM e xAI

Monografia submetida ao curso de graduação em Engenharia de Software da Universidade de Brasília, como requisito parcial para obtenção do Título de Bacharel em Engenharia de Software.

Trabalho aprovado. Brasília, DF, 15 de dezembro de 2025 – Data da aprovação do trabalho:

Dr. Fabiano Araújo Soares
Orientador

Dr. Diogo Caetano Garcia
Convidado 1

MSc. Rafael Santos Ortis
Convidado 2

Brasília, DF
2025

Agradecimentos

Primeiramente, agradeço a Deus e aos meus pais, Wânia e Inácio, que sempre me apoiaram, me incentivaram e me deram plenas condições para focar nos estudos.

Também gostaria de agradecer ao meu orientador, Fabiano Araújo Soares, que sempre se prestou a me ajudar na realização do projeto, participando de reuniões, discutindo assuntos, orientando e indicando caminhos para aprimorar o projeto.

Por fim, agradeço ao meu amigo e parceiro Felipe Direito, que compartilhou comigo os desafios desta etapa final do curso. Além disso, foi o responsável pela indicação do professor Fabiano como orientador e me ajudou sempre que precisei na realização do projeto.

Resumo

A bolsa de valores reflete as mudanças nos preços dos ativos e funciona como um indicador-chave da saúde econômica, evidenciando tendências de alta ou baixa do mercado. Este trabalho mostra que a previsão desse comportamento evoluiu de modelos clássicos de *Machine Learning* (como SVR, CART e MLP) para arquiteturas de *Deep Learning*, em especial redes LSTM, e modelos de *Ensemble* e *Gradient Boosting*, aplicados tanto à Regressão (previsão de valores) quanto à Classificação (movimento e regimes de risco) em mercados desenvolvidos e emergentes. Além disso, também destaca a relevância da escolha do *dataset*, da granularidade temporal, da engenharia de *features* e, mais recentemente, da Inteligência Artificial Explicável (xAI), sobretudo com o uso do SHAP para explicar as decisões de modelos complexos. Alinhado a esse cenário, este trabalho foca na criação de uma metodologia para previsão de séries temporais financeiras no mercado brasileiro, analisando dados diários de mais de 25 anos, pré-processados e estruturados, para treinar uma rede LSTM empilhada implementada em Keras/TensorFlow. O desempenho será avaliado por métricas de Regressão, enquanto o SHAP é aplicado para explicar a contribuição temporal e das variáveis de entrada nas previsões. O objetivo deste projeto foi desenvolver um modelo de previsão do preço das ações do IBOVESPA baseado em LSTM, complementado por xAI, de forma a produzir previsões acuradas e explicáveis que baseiem decisões de risco em mercados emergentes e voláteis como o mercado acionário brasileiro.

Palavras-chave: LSTM, rede neural, previsão de séries temporais, xAI, SHAP, IBOVESPA.

Abstract

The stock market reflects changes in asset prices and serves as a key indicator of economic health, revealing bullish or bearish market trends. This work shows that predicting such behavior has evolved from classical Machine Learning models (such as SVR, CART, and MLP) to Deep Learning architectures, especially LSTM networks, as well as Ensemble and Gradient Boosting models, applied to both Regression (value prediction) and Classification (movement and risk regimes) in developed and emerging markets. Furthermore, it highlights the importance of dataset selection, temporal granularity, feature engineering, and more recently, Explainable Artificial Intelligence (xAI), particularly using SHAP to explain the decisions of complex models. Aligned with this scenario, this work focuses on creating a methodology for forecasting financial time series in the Brazilian market, analyzing daily data spanning over 25 years, pre-processed and structured, to train a stacked LSTM network implemented in Keras/TensorFlow. Performance will be evaluated using Regression metrics, while SHAP is applied to explain the temporal contribution and input variables in the predictions. The objective of this project was to develop an IBOVESPA stock price prediction model based on LSTM, complemented by xAI, in order to produce accurate and explainable predictions that support risk decisions in emerging and volatile markets such as the Brazilian stock market.

Key-words: LSTM, neural network, time series forecasting, xAI, SHAP, IBOVESPA.

Lista de ilustrações

Figura 1 – Índices diários do IBOVESPA. (Fonte: Finance (2025a))	17
Figura 2 – Índices diários do S&P 500. (Fonte: Finance (2026))	17
Figura 3 – Arquitetura da Rede Neural LSTM (Fonte: Yehia (2024))	22
Figura 4 – Diferença entre <i>ensembles</i> de redes neurais e <i>ensembles</i> de árvores de decisão (Fonte: Science (2020))	24
Figura 5 – Volatilidade entre os mercados IBOVESPA (azul escuro) e S&P 500 (azul claro) desde 2000 (Fonte: Finance (2025b))	28
Figura 6 – Fluxo de Projeto (Fonte: Autor)	34

Lista de tabelas

Tabela 1 – Descrição das Variáveis de Negociação OHLCV	16
Tabela 2 – Escolha e Análise dos Modelos de Previsão	25
Tabela 3 – Resumo Comparativo dos Artigos, Foco em Objetivo, Avaliação e Da- dos Utilizados	30
Tabela 4 – Variantes do <i>Ablation Study</i> de Pré-processamento	37
Tabela 5 – Cronograma de Atividades do TCC 2	41

Lista de abreviaturas e siglas

IA	Inteligência Artificial
ML	<i>Machine Learning</i>
RN	Redes Neurais
RNN	<i>Recurrent Neural Network</i>
LSTM	<i>Long Short-Term Memory</i>
XAI	<i>Explainable AI</i>
SHAP	<i>SHapley Additive exPlanations</i>
AT	Análise Técnica
MLP	<i>Multilayer Perceptron</i>
MSE	<i>Mean Squared Error</i>
RMSE	<i>Root Mean Squared Error</i>
MAE	<i>Mean Absolute Error</i>
MAPE	<i>Mean Absolute Percentage Error</i>
CART	<i>Classification and Regression Trees</i>
SVR	<i>Support Vector Regression</i>
SVM	<i>Support Vector Machines</i>
DL	<i>Deep Learning</i>
GBDT	<i>Gradient Boosting Decision Trees</i>
DNN	<i>Deep Neural Network</i>
RSI	<i>Relative Strength Index</i>
MACD	<i>Moving Average Convergence Divergence</i>
VWAP	<i>Volume Weighted Average Price</i>

Sumário

1	INTRODUÇÃO	11
1.1	Motivação	11
1.2	Contextualização do Problema	12
1.3	Impacto	13
1.4	Objetivos	14
1.5	Organização do Trabalho	14
2	REVISÃO BIBLIOGRÁFICA	16
2.1	Introdução à Bolsa de Valores	16
2.1.1	Variáveis de Negociação	17
2.1.1.1	Log-Retornos	19
2.1.2	Normalização	19
2.1.3	Análise Técnica e Análise Fundamentalista	20
2.2	Modelos de Previsão para o Mercado Financeiro	20
2.2.1	Modelos de <i>Machine Learning</i> Clássico	20
2.2.2	Redes Neurais Profundas (<i>Deep Learning</i>)	21
2.2.3	Modelos de <i>Ensemble</i>	23
2.2.4	Análise dos Modelos de Previsão em cada artigo	24
2.3	Abordagens de Previsão e Fontes de Dados	25
2.3.1	Objetivos de Previsão	25
2.3.2	Dados Utilizados	27
2.4	Ferramentas e <i>Frameworks</i>	30
2.5	Emergência da Inteligência Artificial Explicável (xAI)	31
2.5.1	O SHAP como Ferramenta de Interpretabilidade	32
3	METODOLOGIA	33
3.1	Escopo do Projeto	33
3.2	Aquisição de Dados	35
3.3	Pré-processamento de Dados	35
3.4	Modelagem e Arquitetura	38
3.5	Objetivo das Previsões	39
3.6	Estratégia de Interpretabilidade (xAI)	40
4	CRONOGRAMA	41
	REFERÊNCIAS	42

1 Introdução

1.1 Motivação

O mercado de ações é reconhecido como um componente vital de qualquer economia, refletindo as tendências e o desempenho macroeconômico de um país. Índices como o IBOVESPA no Brasil e o S&P 500 nos Estados Unidos servem como termômetros do mercado, orientando investidores e analistas (FERRO et al., 2024). A capacidade de antecipar seus movimentos pode otimizar estratégias de investimento, maximizar lucros e mitigar riscos. Com o avanço da Inteligência Artificial (IA), técnicas de aprendizado de máquina, em especial as redes neurais, têm se mostrado promissoras para modelar os padrões das séries temporais financeiras. No entanto, a previsão do comportamento desses índices ainda é um desafio, dada a natureza complexa, caótica, dinâmica e não-linear das séries temporais financeiras. (FERRO et al., 2024; NELSON, 2017).

Apesar do debate sobre a previsibilidade dos mercados, o grande investimento em Aprendizado de Máquina (ML), em particular, o *Deep Learning*, tem aberto novos e promissores estudos para enfrentar este desafio. Os modelos de previsão baseados em ML e Redes Neurais (RN), como as Redes Neurais Recorrentes (RNN) e *Long Short-Term Memory* (LSTM), têm demonstrado a capacidade de capturar padrões e dependências temporais de longo prazo, superando métodos estatísticos tradicionais (NELSON, 2017).

Contudo, a sofisticação desses modelos, especialmente as redes neurais profundas, frequentemente resultam em um problema de “caixa preta” (*black box*), onde o processo de tomada de decisão interna se torna opaco e de difícil interpretação. (AYATOLLAHI; JAFARI, 2025). Essa falta de transparência compromete a confiança e a adoção prática dessas tecnologias. A falta de interpretabilidade impede que investidores e analistas compreendam quais fatores ou padrões de dados estão influenciando uma determinada previsão, tornando arriscado basear decisões financeiras em um sistema opaco. (GUPTA et al., 2025)

Neste contexto, a Inteligência Artificial Explicável (*xAI - Explainable AI*) surge como um campo crucial, buscando desenvolver métodos para tornar as decisões de modelos de IA compreensíveis para os seres humanos. Técnicas como SHAP (SHapley Additive exPlanations) são essenciais para atribuir a contribuição de cada variável à previsão do modelo, transformando a “caixa preta” em um sistema mais compreensível. (AYATOLLAHI; JAFARI, 2025) A aplicação de xAI no domínio financeiro é uma fronteira de pesquisa recente e de alta relevância, pois promete unir o poder preditivo das redes neurais com a transparência necessária para sua aplicação no mundo real.

1.2 Contextualização do Problema

A previsibilidade do mercado de ações é explorada por meio de diferentes técnicas. Modelos de *Machine Learning* clássico, como Árvores de Decisão, e abordagens de *Ensemble*, como *Gradient Boosting*, são amplamente utilizados. Mais recentemente, as Redes Neurais Recorrentes (RNN), em especial a arquitetura LSTM, ganharam foco nos estudos de séries temporais, como abordaram os trabalhos [Dametto \(2018\)](#), [Nelson \(2017\)](#) e [Gupta et al. \(2025\)](#).

A seleção da ferramenta mais adequada para previsão de séries temporais financeiras envolve tanto linguagens de programação de alto desempenho, como C++ e Java, quanto ambientes voltados à prototipação rápida, como Python. Em aplicações industriais é comum empregar bibliotecas otimizadas em C++ para a implementação dos modelos, enquanto na pesquisa acadêmica e no desenvolvimento experimental prevalecem plataformas de mais alto nível ([PURWAR, 2025](#)). Neste trabalho, o foco recai sobre o ecossistema Python, cuja comunidade é hoje uma das mais ativas em IA e aprendizado de máquina e que dispõe de *frameworks* específicos para *Deep Learning*, como o *TensorFlow* e o *PyTorch*, além de bibliotecas auxiliares para pré-processamento e análise de dados. A escolha do *framework* depende da natureza do problema, do modelo de *Machine Learning* (ML) escolhido e do objetivo da previsão, que pode ser a estimativa de valores futuros (regressão), a classificação da direção do movimento do mercado ou a detecção de eventos raros (*crash*) ([COURSERA, 2025a](#)).

A escolha dos dados de entrada é igualmente crucial, variando desde índices de bolsa (IBOVESPA, S&P 500) até cotações de ações específicas, enriquecidos com indicadores de análise técnica. As séries temporais financeiras são caracterizadas por sua não-linearidade, volatilidade e estocasticidade, o que as torna intrinsecamente difíceis de prever. A modelagem eficaz exige que os algoritmos considerem, além dos dados históricos de preço, a influência de fatores externos (variáveis exógenas) como indicadores de análise técnica (AT) ou cotações de moedas (ex: o Dólar) ([DAMETTO, 2018](#)).

A evolução dos modelos de previsão mostra uma distinção fundamental entre arquiteturas simples e complexas. Enquanto os modelos mais básicos (análogos a redes de camada única ou *single layer*) frequentemente apresentam limitações na captura de padrões complexos e dependências de longo prazo, arquiteturas como o *Multilayer Perceptron* (MLP) e as redes de *Deep Learning* (como LSTM e CNN) são capazes de modelar problemas não-linearmente separáveis graças à sua composição de múltiplas camadas intermediárias ([FERRO et al., 2024](#)).

Para superar as limitações dos modelos individuais (*single*), as técnicas de *ensemble* foram desenvolvidas com o objetivo de combinar múltiplos modelos (homogêneos ou heterogêneos) para aumentar a robustez e acurácia da previsão. Essas abordagens incluem

estratégias como *Bagging*, *Stacking* e Sistemas Híbridos Residuais (FERRO et al., 2024). O desempenho desses modelos é avaliado utilizando métricas de desempenho tradicionais de regressão, como o Erro Quadrático Médio (MSE), Raiz do Erro Quadrático Médio (RMSE), Erro Absoluto Médio (MAE) e Erro Percentual Absoluto Médio (MAPE). Em certas análises, uma métrica de custo-benefício é aplicada para verificar se o aumento na complexidade do modelo é justificado pelo ganho de desempenho e eficiência computacional (DAMETTO, 2018).

Apesar do aumento da precisão, modelos complexos como os ensembles e redes neurais profundas permanecem como uma “caixa preta” (*black box*). O problema central abordado neste trabalho é a falta de interpretabilidade dos modelos de redes neurais aplicados à previsão do mercado de ações. Para enfrentar essa lacuna, este trabalho foca na aplicação de técnicas de xAI para elucidar o comportamento de um modelo de previsão de mercado. A questão de pesquisa que guia este estudo é: *Como desenvolver um modelo de previsão para o mercado de ações baseado em redes neurais que não apenas alcance um desempenho preditivo satisfatório, mas que também ofereça interpretabilidade sobre os fatores que influenciam suas decisões?*

1.3 Impacto

A capacidade de previsão de séries temporais financeiras é vital, pois fornece aos investidores informações de referência essenciais para avaliações de curto, médio e longo prazo, conferindo maior segurança ao investimento. Este trabalho contribui diretamente ao campo do *algorithmic trading* ao focar em modelos de previsão de alto desempenho.

Em particular, a utilização de Redes Neurais, como a LSTM, é altamente relevante. As LSTMs são variações de redes recorrentes que se destacam por sua capacidade de reter dependências temporais de longo prazo, o que as torna modelos de *Deep Learning* mais adequados para a modelagem da natureza sequencial e volátil dos dados do mercado de ações. A tecnologia de Redes Neurais que o trabalho aborda é, portanto, uma das mais promissoras no campo. (GUPTA et al., 2025)

Embora o poder preditivo de modelos complexos, como os *ensembles* e LSTMs, seja inegável, entender o porquê de uma previsão é tão ou mais importante do que a sua precisão. A abordagem deste trabalho, que integra modelos de previsão avançados com a Inteligência Artificial Explicável (xAI), ataca diretamente este problema. O uso de técnicas como SHAP é a relevância da tecnologia abordada, pois elas fornecem a interpretabilidade local e global necessária, transformando a opacidade em transparência. (OHANA et al., 2021)

O impacto deste estudo se manifesta por meio das seguintes contribuições:

1. Desenvolver um modelo de previsão robusto para o mercado de ações que combine as capacidades de Redes Neurais (LSTM) com a interpretabilidade da xAI.
2. Apresentar um *framework* prático para a integração de xAI no processo de *Deep Learning* aplicado à previsão de séries temporais financeiras.
3. Oferecer *insights* economicamente coerentes sobre quais fatores (e.g., cotações passadas, indicadores técnicos) realmente influenciam as decisões do modelo (via SHAP).

Dessa forma, o estudo contribui para o avanço de sistemas de análise financeira que não são apenas preditivamente robustos, mas também transparentes e confiáveis.

1.4 Objetivos

Este trabalho tem como propósito desenvolver, treinar e validar uma modelo de Rede Neural Recorrente LSTM para previsão de séries temporais do mercado de ações brasileiro, integrando uma ferramenta de xAI para obter explicações sobre as decisões do modelo de regressão. Para alcançar esse resultado, foram estabelecidos os seguintes objetivos:

- Adquirir o *dataset* da bolsa de valores e tratar os dados em um formato estruturado para o aprendizado de máquina.
- Construir a arquitetura da Rede Neural e definir a ferramenta/*framework* de implementação.
- Treinar e validar o modelo de previsão para comprovar sua capacidade preditiva.
- Gerar previsões e avaliar o desempenho do modelo utilizando as principais métricas de desempenho para o objetivo de predição.
- Integrar o modelo treinado com a ferramenta xAI para extrair explicações sobre suas previsões.

1.5 Organização do Trabalho

Este trabalho está organizado da seguinte forma. Inicialmente no primeiro capítulo foi feita uma introdução do trabalho, os problemas que contextualizaram a pesquisa e os objetivos gerais e específicos. No capítulo 2 é desenvolvida a Revisão Bibliográfica, onde são apresentados os principais conceitos teóricos relacionados à previsão de valores de séries temporais no mercado financeiro, bem como os trabalhos correlatos que fundamentam a pesquisa. Em seguida, no capítulo 3, na Metodologia, estão descritos os procedimentos

adotados para a realização do estudo, incluindo as estratégias de coleta e tratamento dos dados, as ferramentas e técnicas utilizadas, além dos critérios de avaliação empregados.

2 Revisão Bibliográfica

Este capítulo apresenta uma revisão bibliográfica sobre as técnicas de inteligência artificial aplicadas à previsão do mercado de ações da bolsa de valores. A análise se baseia em artigos que exploram diferentes modelos, abordagens e ferramentas para extrair padrões de séries temporais financeiras.

2.1 Introdução à Bolsa de Valores

A bolsa de valores é um componente vital do sistema financeiro, atuando como o ambiente/mercado onde são negociados títulos de longo, médio e curto prazo. Um dos principais componentes do mercado de capitais são as ações, que representam a propriedade parcial de uma empresa, isto é, os investidores que compram ações tornam-se acionistas e podem ganhar dinheiro por meio de dividendos e valorização do preço das ações. Além disso, os índices de mercado são derivados do desempenho das ações, que refletem as mudanças nos preços do mercado financeiro e servem como um indicador-chave de desempenho de um conjunto de ações representativas. No Brasil, o principal indicador de desempenho é o Índice Bovespa (IBOVESPA), enquanto nos Estados Unidos, o principal indicador de desempenho é o S&P 500, eles são compostos pelas ações mais negociadas e representativas, indicando tendências de alta ou baixa do mercado desse país (FERRO et al., 2024). As variáveis de entrada das ações desses mercados são as variáveis padrão de negociação (OHLC), além do volume e do preço ajustado, base das análises técnicas, e estão descritas de forma resumida na Tab. 1 Finance (2025a). As figuras 1 e 2 exemplificam a variação diária desses indicadores em ambos os mercados.

Tabela 1 – Descrição das Variáveis de Negociação OHLCV

Variável	Descrição
<i>Open</i>	Preço do ativo no momento da abertura do pregão.
<i>High</i>	Preço máximo atingido pelo ativo durante o período de negociação.
<i>Low</i>	Preço mínimo atingido pelo ativo durante o período de negociação.
<i>Close</i>	Preço do ativo no momento do fechamento do pregão.
<i>Adj Close</i>	Preço de fechamento ajustado por eventos corporativos (dividendos, desdobramentos).
<i>Volume</i>	Quantidade total de ativos negociados durante o período.




Figura 1 – Índices diários do IBOVESPA. (Fonte: Finance (2025a))




Figura 2 – Índices diários do S&P 500. (Fonte: Finance (2026))

2.1.1 Variáveis de Negociação

As variáveis padrão de negociação, conhecidas como OHLC (*Open*, *High*, *Low*, *Close*), são os dados fundamentais utilizados na análise técnica do mercado de ações. Essas variáveis pode ser representadas por gráficos OHLC, que exibem os quatro principais

pontos de dados ao longo de um período (onde o preço começou, onde foi mais alto, mais baixo e onde terminou), sendo o preço de fechamento considerado o mais importante por muitos traders. Dentre os padrões analisados, a máxima e a mínima mostram a amplitude total do preço no período, o que é útil para avaliar a volatilidade. Por meio desses gráficos, é possível avaliar o comportamento do preço de um ativo em um único período, com riqueza de detalhes. A seguir estão melhor descritas essas variáveis pelo [Capital \(2025\)](#).

- **Open (Abertura):** Representa o primeiro preço pelo qual o ativo começou a ser negociado no início do período. Este valor é importante pois dependendo do preço de fechamento indica o sentimento do mercado, refletindo o comportamento/expectativas dos investidores no período.
- **High (Máxima):** Representa o preço mais alto atingido pelo ativo durante o período de negociação. Esse valor pode indicar nível de resistência, ou seja, um ponto em que os compradores perderam força, ou até onde o mercado esteve disposto a pagar por ele, rejeitando preços mais altos.
- **Low (Mínima):** Representa o preço mais baixo atingido pelo ativo durante o período. A mínima indica o ponto de maior pessimismo e é utilizada para identificar níveis de suporte, onde a pressão compradora tende a superar a vendedora, recuperando seu valor.
- **Close (Fechamento):** É o último preço registrado no final do período. O preço de fechamento é considerado o mais importante pelos analistas técnicos, pois representa o consenso final do mercado sobre o valor do ativo no período e serve como referência para o cálculo de diversos indicadores.
- **Adj Close (Fechamento Ajustado):** É o preço de fechamento corrigido para refletir eventos corporativos que afetam o valor da ação, como desdobramentos de ações e dividendos. É um reflexo mais preciso do valor de uma ação, pois leva em consideração todos os fatores que podem afetar o preço da ação após o fechamento do mercado. Essa variável é essencial para análises de longo prazo, pois permite comparar preços históricos de forma consistente, eliminando distorções causadas por esses eventos ([INVESTOPEDIA, 2025b](#)).
- **Volume:** Representa a quantidade total de ações negociadas durante o período. O volume é um indicador de liquidez e interesse do mercado, sendo utilizado para confirmar tendências de preço. Um movimento de alta acompanhado de volume crescente é considerado mais significativo do que um movimento com volume decrescente ([INVESTOPEDIA, 2025a](#)).

2.1.1.1 Log-Retornos

O log-retorno é uma transformação que converte a série de preços absolutos em uma série de variações relativas e representa a variação percentual do preço em escala logarítmica, removendo tendência, escala de preços e tratando ganhos e perdas de forma simétrica. Ele é calculado como:

$$\logret_t = \log \left(\frac{P_t}{P_{t-1}} \right) \quad (2.1)$$

onde P_t é o preço de fechamento do dia t e P_{t-1} é o preço do dia anterior.

Quando o input do modelo é definido como “log-retornos”, todas as *features* derivadas (médias móveis, volatilidade, RSI, etc.) são calculadas sobre a série de log-retornos em vez de sobre o preço bruto.

2.1.2 Normalização

Antes de alimentar os dados aos modelos de previsão, é comum aplicar transformações aos preços brutos para melhorar a performance e estabilidade do treinamento. A normalização é o processo de escalar os dados para um intervalo ou distribuição específica, melhorando a convergência do treinamento e a estabilidade numérica. As duas técnicas mais comuns em séries temporais financeiras são:

- **Z-score (Padronização):** Transforma os dados para ter média zero e desvio padrão unitário. É calculado como:

$$z = \frac{x - \mu}{\sigma} \quad (2.2)$$

onde μ é a média e σ é o desvio padrão dos dados de treino.

- **Min-Max (Normalização):** Escala os dados para o intervalo $[0, 1]$. É calculado como:

$$x_{norm} = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (2.3)$$

onde $x_{\min}$ e $x_{\max}$ são os valores mínimo e máximo dos dados de treino.

Em séries temporais financeiras, é crucial que os parâmetros de normalização (μ , σ , $x_{\min}$, $x_{\max}$) sejam calculados exclusivamente nos dados de treino e aplicados sem recalibração nos conjuntos de validação e teste. Isso evita vazamento de informação do futuro para o passado, garantindo que o modelo avalie sua capacidade de generalização para regimes não vistos durante o treinamento.

2.1.3 Análise Técnica e Análise Fundamentalista

Existem basicamente dois modelos para apoiar estratégias de investimento na bolsa de valores, a Análise Técnica e a Análise Fundamentalista. Essas duas escolas de pensamento estão em extremos opostos, porém ambas são usadas para prever tendências futuras nos preços de ações e, como qualquer estratégia ou filosofia de investimento, há diversas particularidades que as tornam muito diferentes entre si. De modo geral, a análise técnica lida com a avaliação dos movimentos de preços e gráficos de preços para prever os próximos movimentos do mercado, enquanto a análise fundamentalista se concentra mais nos elementos que estruturam uma empresa, como a produtividade, os lucros, a saúde financeira, dívidas, novos projetos e até questões mais subjetivas como cultura da companhia, engajamento dos colaboradores e liderança (XP, 2024).

2.2 Modelos de Previsão para o Mercado Financeiro

A previsão de séries temporais financeiras é uma área desafiadora, dada a natureza caótica, volátil e não estacionária dos dados do mercado. Historicamente, essa tarefa evoluiu de modelos estatísticos lineares para algoritmos de *Machine Learning* (ML) mais sofisticados, que podem ser categorizados amplamente em modelos clássicos, Redes Neurais Profundas e Modelos de *Ensemble*.

2.2.1 Modelos de *Machine Learning* Clássico

Os modelos clássicos de *Machine Learning* (ML) são amplamente utilizados como *benchmarks* ou em arquiteturas mais simples para a previsão de séries temporais financeiras. Eles são valorizados devido à sua simplicidade e eficácia em capturar relações não lineares nos dados. Modelos como Árvore de Decisão (CART), *Support Vector Regression* (SVR) e *Multilayer Perceptron* (MLP) são frequentemente utilizados e serão detalhados a seguir:

- *Support Vector Regression* (SVR)

É uma alternativa à SVM (*Support Vector Machines*) utilizada para regressão. Ela emprega os princípios das SVMs para transformar as características de entrada em espaços de alta dimensionalidade, a fim de localizar o hiperplano ideal que representa os dados com precisão (SETHI, 2025). Em Ferro et al. (2024), o SVR foi incluído por sua capacidade de lidar com dados não lineares. Apesar disso, uma grande desvantagem foi que o SVR exigiu uma seleção cuidadosa dos kernels e parâmetros, sendo que uma escolha inadequada impacta o tempo de convergência.

- Árvore de Decisão (CART)

Este modelo é um algoritmo de árvore de decisão que divide recursivamente os dados em subconjuntos com base nos valores das variáveis de entrada, criando, em última instância, uma estrutura em forma de árvore que pode ser usada para previsão (GUNAY, 2023). O CART demonstrou-se eficaz na captura de relações não lineares e, em Ferro et al. (2024), destacou-se por ter o melhor custo-benefício em mercados desenvolvidos como o S&P 500. Sua principal desvantagem é a suscetibilidade ao *overfitting* na presença de dados ruidosos.

- *Multilayer Perceptron* (MLP)

É um tipo de rede neural artificial que consiste em várias camadas de neurônios. Ela é organizada em camadas, começando pela camada de entrada, na qual os dados são introduzidos. Em seguida, há as camadas ocultas, onde são realizados os cálculos e, por fim, a camada de saída, onde são feitas as previsões ou tomadas as decisões. Os neurônios das camadas adjacentes são conectados por conexões ponderadas, que transmitem sinais de uma camada para a outra (datacamp, 2024). Embora seja a forma mais simples de Rede Neural, o MLP é frequentemente classificado como um modelo de ML clássico em comparações mais amplas. Essa arquitetura utiliza o algoritmo *backpropagation* para ajustar pesos e determinar o grau de influência (GIACOMEL, 2016).

2.2.2 Redes Neurais Profundas (*Deep Learning*)

As Redes Neurais Profundas (DL) representam a subárea do ML mais utilizada para a previsão financeira, dada sua capacidade de modelar a complexidade e a não-linearidade dos dados de mercado. A arquitetura *Multilayer Perceptron* (MLP) serve como base do *Deep Learning*. Um MLP é uma rede do tipo *feedforward*, composta por camadas de neurônios onde a informação flui em uma única direção, da entrada para a saída. Já a arquitetura *Long Short-Term Memory* (LSTM) é uma rede do tipo recorrente, composta por camadas de neurônios onde a informação flui em mais de uma direção. Como processa cada entrada de forma independente, possuem um mecanismo de memória interna que lhes permite reter informações de observações anteriores, tornando-as o ideais para modelar as dependências temporais de séries financeiras (NIMBUS, 2018).

- *Long Short-Term Memory* (LSTM)

É um tipo de Rede Neural Recorrente (RNN) que tende a resolver problemas de dependências de longo prazo. Foram amplamente utilizadas nos estudos por terem uma memória de curto prazo que permitia reter informações para capturar padrões temporais e ignorar flutuações irrelevantes. Em (NELSON, 2017), a LSTM foi considerada mais apropriada para séries temporais do que outros algoritmos por sua

memória. A principal desvantagem é que são frequentemente modelos “caixa preta” que carecem de interpretabilidade.

Sua arquitetura consiste em conexão sequencial de células LSTM, formando uma cadeia. A informação flui ao longo dessa cadeia por dois caminhos principais: o estado da célula (C_t) e o estado oculto (H_t). O estado da célula transporta o contexto das informações a longo prazo, e é regulado pelas portas para adicionar ou remover informações sem destruir o contexto anterior. O estado oculto representa o conhecimento de curto prazo da célula atual e serve como sua saída, sendo alimentado (junto com a nova entrada X_{t+1}) para a próxima célula da sequência. Essa estrutura em cadeia permite que a rede mantenha a memória de eventos distantes/dependências de longo prazo. A Fig. 3 representa a arquitetura das células de um rede LSTM.




Figura 3 – Arquitetura da Rede Neural LSTM (Fonte: Yehia (2024))

De forma geral, as células LSTM contém três camadas interconectadas, comumente chamadas de portas. Essas portas usam uma função de ativação sigmoide, filtrando as informações que devem ser aproveitadas.

- Porta de Esquecimento (*Forget Gate*): Decide quais informações do estado da célula anterior (C_{t-1}) devem ser descartadas por não serem mais relevantes para a previsão atual.
- Porta de Entrada (*Input Gate*): Determina quais novas informações (X_t) serão armazenadas no estado da célula.
- Porta de Saída (*Output Gate*): Define quais partes do estado da célula (C_t) serão usadas para o estado oculto atual (H_t) e que será passada adiante.

- *Extended LSTM* (xLSTM-TS)

Proposta por Gil, Duhamel-Seblin e McCarren (2024) como evolução da LSTM clássica, a xLSTM introduz duas novas células de memória: a *sLSTM* (*scalar LSTM*), que incorpora *exponential gating* para melhor controle do fluxo de informação, e a *mLSTM* (*matrix LSTM*), que substitui o vetor de memória escalar por uma matriz, ampliando a capacidade de armazenamento de contexto de longo prazo. O repositório xLSTM-TS (GIL; DUHAMEL-SEBLIN; MCCARREN, 2024) adapta essa arquitetura para previsão univariada de séries temporais, integrando pré-processamento com *denoising* wavelet para redução de ruído de alta frequência, e avalia o modelo em dados do S&P 500 e do ETF EWZ.

- *Transformer* para Séries Temporais

O *Transformer* foi proposto por Vaswani et al. (2017) para processamento de linguagem natural, eliminando a recorrência e substituindo-a pelo mecanismo de *self-attention*, que pondera a relevância de cada posição da sequência em relação a todas as outras de forma paralela. A unidade central é a atenção multi-cabeça (*multi-head attention*), que projeta a sequência de entrada em múltiplas representações de *query*, *key* e *value*, capturando diferentes padrões de dependência simultaneamente. A posição temporal é codificada por *positional embeddings* em vez de ordem recorrente. A arquitetura original é composta por um codificador e um decodificador; para tarefas de previsão de séries temporais, apenas o bloco codificador é tipicamente utilizado.

2.2.3 Modelos de *Ensemble*

Como forma de diminuir as limitações dos modelos previsão individuais, os *ensembles* combinam múltiplas previsões para aumentar a robustez e acurácia das previsões. Ou seja, os *ensembles* a partir de vários modelos de *machine learning*, constroem o resultado final a partir do resultado de cada modelo de previsão, obtendo-se assim um valor final único (TECH, 2024). Entre as abordagens estudadas nos artigos, destacam-se os *ensembles* de redes neurais, que utilizam métodos de votação ou média para chegar a uma decisão final, e os *ensembles* de que utilizam árvores de decisão, como o *Gradient Boosting* (XGBoost, GBDT), para chegar a um resultado. Apesar de ambos os *ensembles* apresentarem um resultado de saída, sua decisão é realizada de forma diferente em cada caso. A Fig. 4 ilustra a diferença entre os dois tipos de *ensembles*.

- *Ensembles* de Redes Neurais (*Bagging*)

É a combinação de duas ou mais redes neurais (frequentemente MLP) treinadas para o mesmo problema, agregando suas saídas por métodos como média ou votação. Em (GIACOMEL, 2016), a utilização do *ensemble* demonstrou que a redundância de várias redes diminui o erro, superando o desempenho de RNs sozinhas.

- *Gradient Boosting* (GBDT/XGBoost/LightGBM)

Trata-se de um *ensemble* sequencial de árvores de decisão que constrói novas árvores com o objetivo minimizar o erro do modelo anterior, por meio de uma função de perda. O GBDT é considerado ideal para problemas de classificação com *datasets* pequenos e desbalanceados, como a previsão de crises. O XGBoost e o LightGBM (GBDT) quando testados apresetaram desempenho similares de aprendizado. (OHANA et al., 2021)




Figura 4 – Diferença entre *ensembles* de redes neurais e *ensembles* de árvores de decisão (Fonte: Science (2020))

2.2.4 Análise dos Modelos de Previsão em cada artigo

A escolha do modelo em cada artigo foi motivada por um objetivo específico. A Tab. 2 resume os modelos de previsão selecionados e a justificativa para sua utilização em cada estudo:

Tabela 2 – Escolha e Análise dos Modelos de Previsão

Artigo	Modelo Escolhido	Motivação
Giacomel (2016)	Ensembles de Redes Neurais MLP	Redes Neurais do tipo MLP entregam melhores resultados na previsão e Ensembles fornecem melhor generalização e melhores resultados.
Dametto (2018)	Ensemble de Redes Neurais MLP, NARX, LSTM	Combinar o resultado de três redes neurais e comparar o desempenho do método Ensemble.
Ferro et al. (2024)	Ensembles dos métodos MLP, SVR, CART, ARIMA	Cobrir uma ampla gama de abordagens reconhecidas na literatura, permitindo uma análise comparativa aprofundada.
Nelson (2017)	Rede Neural LSTM	Redes Neurais Recorrentes são mais apropriadas para séries temporais por terem memória de curto prazo.
Ayatollahi e Jafari (2025)	Ensemble de Árvores de Decisão (XGBoost)	Alta performance preditiva e mais adequado para interpretação via xAI.
Ohana et al. (2021)	GBDT (Gradient Boosting Decision Trees)	Método mais adequado para problemas de classificação em <i>datasets</i> pequenos e desbalanceados.
Gupta et al. (2025)	Rede Neural LSTM	Capacidade de lidar com sequências de dados e dependências de longo prazo.

2.3 Abordagens de Previsão e Fontes de Dados

A escolha dos dados de análise e a definição da forma como os dados serão previstos são fundamentais para a validação do estudo. A análise dos artigos revela uma diferença entre os objetivos da previsão (regressão vs. classificação) e as fontes de dados utilizadas (mercados desenvolvidos vs. emergentes). Nesta seção, serão discutidos os principais objetivos, as fontes de dados utilizadas e as diferentes métricas de avaliação das previsões nos estudos.

2.3.1 Objetivos de Previsão

O problema da previsão financeira é frequentemente abordado sob diferentes perspectivas. Nos artigos analisados, destacam-se duas abordagens principais: a Regressão, que visa prever o valor exato do índice ou preço no futuro, e a Classificação, que busca apontar a direção futura do movimento de preços (alta ou baixa). Outro objetivo utilizado foi a detecção de eventos críticos, como crises ou quedas abruptas (*crashes*), que apesar de ser um considerado uma classificação de evento de alto impacto, também pode ser indicada a partir de modelos de regressão que preveem variações de grande magnitude.

A avaliação das previsões no mercado financeiro é tão importante quanto a própria arquitetura do modelo, pois determinam sua confiabilidade e relevância. Os artigos ana-

lisados demonstraram que as métricas de avaliação dependem do seu objetivo, variando de acordo com os método de Regressão ou Classificação. A seguir, serão detalhadas as formas de avaliação das previsões nos artigos.

- **Regressão (Previsão de Valor):**

A avaliação de modelos de regressão, que preveem o valor exato de um ativo, foca em quantificar a magnitude do erro. Para isso, são utilizadas métricas padrão como o Erro Quadrático Médio (MSE) e sua raiz (RMSE), e o Erro Percentual Absoluto Médio (MAPE), que expressa o erro em porcentagem. Além disso, o Coeficiente de Determinação (R^2) pode ser utilizado para avaliar a proporção da variância dos dados que é explicada pelo modelo, indicando seu poder de ajuste. Em análises mais abrangentes, o desempenho do modelo pode ser ponderado pelo seu custo computacional, buscando um equilíbrio entre precisão e eficiência. Adicionalmente, métricas de classificação, como a precisão da direção do movimento (alta ou baixa), podem complementar a análise, oferecendo uma perspectiva prática sobre a utilidade do modelo para a tomada de decisão.

Em [Dametto \(2018\)](#), [Ferro et al. \(2024\)](#) foram utilizadas métricas de erro tradicionais (MSE, RMSE, MAPE) para medir a proximidade entre o valor previsto e o valor real do índice (IBOVESPA e S&P 500). [Ferro et al. \(2024\)](#) alcançou RMSE de 2.5% no S&P 500 usando *ensembles* de redes neurais.

Em [Gupta et al. \(2025\)](#) o foco foi na regressão de valores futuros para o preço de fechamento de ações específicas (HDFC Bank), utilizando o R^2 para medir o ajuste do modelo.

- **Classificação (Previsão de Movimento ou Risco):**

Em previsões de classificação, como prever a direção dos preços (alta/baixa) ou detectar eventos raros como crises, a avaliação se diferencia da regressão, pois foca na capacidade do modelo de acertar a classe correta. A acurácia é direta e mede o percentual geral de acertos. No entanto é necessário fazer uma avaliação mais aprofundada em alguns casos, como o cenário com dados desbalanceados, onde consequentemente a maioria dos dias é de “não crise” e apenas poucos dias são de “crise”, resultando em um acerto da maioria das previsões apenas escolhendo sempre a classe majoritária (não crise). Em casos como esses, como a acurácia pode não refletir o resultado real, métricas como Precisão, *Recall* e *F1-Score* são alternativas, pois avaliam o desempenho de acordo com a identificação dos eventos de interesse (positivos verdadeiros) e não com a previsão da ausência de eventos (negativos verdadeiros).

- **Precisão:** Mede quantos dos eventos previstos como positivos realmente são positivos.

- **Recall**: Mede quantos dos eventos positivos reais foram corretamente identificados.
- **F1-Score**: Média harmônica entre precisão e *recall*.
- **MCC (*Matthews Correlation Coefficient*)**: correlação entre o que o modelo previu e o que realmente aconteceu, considerando todos os quadrantes da matriz de confusão (VP, FP, VN, FN). Única métrica que penaliza igualmente errar "sobe" e errar "cai".

Em [Giacomel \(2016\)](#), [Nelson \(2017\)](#) os problemas de previsão de movimento são tratados como classificação binária, gerando sinais diretos de Compra/Venda a partir da previsão de Subir/Não Subir. [Nelson \(2017\)](#) avaliou modelos no curtíssimo prazo usando o conjunto padrão de métricas: Acurácia, Precisão, Revocação (*Recall*) e Medida F1.

Em [Ayatollahi e Jafari \(2025\)](#), [Ohana et al. \(2021\)](#), foi abordada a previsão de eventos de crise, utilizando métricas para dados desbalanceados, como o AUC (*Area Under the Curve*) e o PR AUC (*Precision-Recall AUC*). [Ayatollahi e Jafari \(2025\)](#) priorizou o F1-Score (0.8364), métrica que equilibra Precisão e *Recall*.

2.3.2 Dados Utilizados

A escolha do *dataset* (conjunto de dados) é o ponto de partida para qualquer modelo de previsão, e pode ser o responsável pelo sucesso ou fracasso do modelo. A análise dos artigos demonstra uma grande variação na escolha dos dados, que se diferenciam pela natureza do mercado (emergente vs. desenvolvido), granularidade temporal e features utilizadas.

- **Natureza do Mercado:**

Um dos fatores que influenciam a escolha do *dataset* é a volatilidade e a previsibilidade esperada. Mercados desenvolvidos são caracterizados por terem uma menor volatilidade e um crescimento mais estável. O S&P 500 (Estados Unidos) é o índice mais utilizado para representar esse cenário, utilizado nos artigos [Giacomel \(2016\)](#) [Ferro et al. \(2024\)](#) e [Ohana et al. \(2021\)](#). Em [Ferro et al. \(2024\)](#), foram comparados os mercados S&P 500 e IBOVESPA, no qual confirmou que o mercado norte-americano demonstrou uma menor assimetria e menor variação em suas cotações, representando uma maior estabilidade, enquanto o IBOVESPA apresentou maior assimetria, instabilidade e propensão a flutuações bruscas, dificultando sua previsão. Mesmo com ambos mercados oscilando bastante, a Fig. 5 demonstra a diferença de volatilidade entre os mercados desde o ano 2000. Dentre os mercados emergentes estudados nos artigos estão IBOVESPA (Brasil), TEPIX (Bolsa de Valores de Teerã) e HDFC Bank (Índia).



Figura 5 – Volatilidade entre os mercados IBOVESPA (azul escuro) e S&P 500 (azul claro) desde 2000 (Fonte: [Finance \(2025b\)](#))

Apesar de ser mais simples prever um mercado com menor volatilidade, são nos mercados emergentes que se encontram os desafios e consequentemente as maiores oportunidades. Como visto no [Giacomet \(2016\)](#), prever esses mercados possibilita chances de ganhos maiores ao investidor, porém existe um déficit de pesquisa nesta área relativo aos mercados emergentes, pois muito do que já foi feito está consolidado apenas para os mercados desenvolvidos. Ainda há muito o que se pesquisar no campo dos mercados emergentes, o qual a meta é atingir alta rentabilidade mesmo em ambientes de maior instabilidade.

Em contrapartida, a maior estabilidade dos mercados desenvolvidos os torna adequados para a validação inicial de metodologias de previsão, pois permitem isolar o efeito dos modelos sem a interferência da alta volatilidade. Como observado em [Ferro et al. \(2024\)](#), o S&P 500 apresenta menor assimetria e variação em suas cotações, o que facilita a identificação de padrões consistentes. Uma vez que os métodos são validados em mercados desenvolvidos, sua aplicação a mercados emergentes pode avaliar a robustez das abordagens em cenários de maior instabilidade. Em [Giacomet \(2016\)](#), observou-se que prever mercados emergentes possibilita chances de ganhos maiores ao investidor, porém existe um déficit de pesquisa nesta área relativo aos mercados emergentes.

- **Características dos Dados**

Muito se fala no indicador do preço das ações, porém isso é apenas um indicador de uma série temporal. A diversidade de *features* (variáveis de entrada) nos *datasets* reflete a complexidade dos mercados financeiros, que são influenciados por fatores que vão além da observação de preços históricos. As *features* podem ser divididas em categorias para fornecer ao modelo uma visão melhor do ambiente de risco e oportu-

nidade: as *features* com características mais técnicas são derivadas da ação histórica do preço e volume, como as Médias Móveis, o RSI (Índice de Força Relativa), o MACD (Convergência/Divergência de Médias Móveis) e o VWAP (Preço Médio Ponderado por Volume), e são cruciais para modelos de curto prazo e alta frequência (AYATOLLAHI; JAFARI, 2025). Em contrapartida, como visto em Ohana et al. (2021), os estudos de risco e regimes incorporaram *features* macroeconômicas, que refletem a saúde e o sentimento mais amplos da economia, abrangendo taxas de juros, P/E (*Price/Earnings ratios*), crescimento de vendas e índices de surpresa econômica. Essas *features* são importantes para a previsão de eventos de crise, pois a probabilidade de um *crash* é impulsionada não só pelo preço do ativo, mas também pela aversão global ao risco e pelas tendências econômicas.

Outro fator relevante que caracteriza os dados é a granularidade temporal, referente à frequência ou ao intervalo de tempo entre observações sucessivas do dado (e.g., diário, a cada 15 minutos). A escolha da granularidade é relevante para o horizonte de previsão e o tipo de fenômeno que o modelo pode prever. Geralmente modelos diários/baixa frequência são mais adequados para capturar grandes ciclos de mercado e prever eventos de risco (crises), pois filtram o “ruído” do mercado intradiário, enquanto modelos de alta frequência são sensíveis às flutuações rápidas e são essenciais para *algotrading* de alta velocidade.

- **Pré-processamento: *Denoising Wavelet***

Séries financeiras diárias contêm um componente significativo de ruído de alta frequência que pode prejudicar a aprendizagem dos modelos. A Transformada Wavelet Discreta (DWT) é uma técnica que decompõe o sinal em componentes de diferentes frequências e elimina aqueles de baixa energia (ruído), preservando as estruturas de tendência e ciclo. Diferentemente da normalização simples, o *denoising wavelet* atua na própria forma do sinal. Para evitar vazamento de dados, a aplicação deve ser causal: o limiar de corte é calculado apenas nos dados de treino e o modo de extensão de bordas deve ser **zero-padding**, garantindo que cada ponto t utilize somente dados de instantes anteriores.

A seguir a Tab. 3 que resume os artigos estudados, destacando o objetivo de previsão e como foram avaliados, e os dados utilizados e suas características.

Tabela 3 – Resumo Comparativo dos Artigos, Foco em Objetivo, Avaliação e Dados Utilizados

Artigo	Objetivo de Previsão	Avaliação	Dados Utilizados
Giacomel (2016)	Classificação de Movimento: Alta/Baixa	Rentabilidade Financeira e Acurácia.	Ações mais negociadas dos mercados S&P 500 e BOVESPA.
Dametto (2018)	Regressão.	MSE, RMSE, MAPE e Precisão Movimento.	IBOVESPA e cotação do Dólar.
Ferro et al. (2024)	Regressão.	RMSE, MAE e custo-benefício.	IBOVESPA e S&P 500.
Nelson (2017)	Classificação de Movimento: Alta/Baixa	Acurácia, F1 e Rentabilidade Financeira.	Ativos de maior negociação do IBOVESPA.
Ayatollahi e Jafari (2025)	Classificação de Risco: <i>Crash Event</i>	F1-Score, AUC/PR AUC.	TEPIX.
Ohana et al. (2021)	Classificação de Risco: Regime de Crise/Normal	Acurácia, Precisão, Recall, F1-Score e AUC.	S&P 500.
Gupta et al. (2025)	Regressão	RMSE e R^2 .	Ação HDFC <i>Bank</i> .

2.4 Ferramentas e *Frameworks*

A busca de melhores resultados de previsão envolve não somente a característica do dado e seu modelo de previsão, mas também a qualidade e robustez da ferramenta/*framework* que é utilizada para implementar e avaliar o modelo. Em geral, são utilizadas linguagens e bibliotecas voltadas ao aprendizado de máquina, que oferecem estrutura para construção e treinamento de redes neurais e/ou implementações de algoritmos clássicos de previsão. As ferramentas utilizadas nos artigos demonstram uma divisão clara entre as necessidades de *Deep Learning*, *Machine Learning* clássico e a nova demanda por Interpretabilidade (xAI).

- ***Frameworks* de Deep Learning (DL):**

Para a construção de Redes Neurais mais complexas, como as arquiteturas recorrentes, a maioria dos estudos utilizou o Keras/TensorFlow. O Keras atua como a interface que simplifica a definição das camadas, enquanto o TensorFlow serve como *backend* que executa os cálculos pesados (COURSERA, 2025a). [Giacomel \(2016\)](#) foi o único artigo que utilizou o *framework* Encog para implementar suas Redes Neurais MLP, por ser a ferramenta mais vantajosa na época, anterior à popularização do Keras/TensorFlow. Em compensação, o Keras/TensorFlow foram utilizados nos

artigos [Dametto \(2018\)](#), [Nelson \(2017\)](#), [Ohana et al. \(2021\)](#), [Gupta et al. \(2025\)](#). Em trabalhos mais recentes voltados a arquiteturas SOTA, o **PyTorch** tem se consolidado como *framework* preferencial, por oferecer maior flexibilidade para arquiteturas customizadas e suporte nativo a múltiplos *backends* de aceleração; esse é o caso do repositório xLSTM-TS [Gil, Duhamel-Seblin e McCarren \(2024\)](#), que implementa a arquitetura diretamente em PyTorch.

- ***Frameworks de Machine Learning (ML) Clássico e Ensembles:***

Para modelos tradicionais (MLP, SVR, CART) e para a estruturação de arquiteturas de *ensemble*, o Scikit-learn foi a biblioteca principal. O Scikit-learn é comumente utilizado, pois é uma biblioteca de aprendizado de máquina de fácil implementação e que suporta a implementação de vários modelos de dados e algoritmos de aprendizado de máquina por meio de APIs Python consistentes para o pré-processamento, a validação e a criação de modelos de *ensemble* como *Bagging* e *Stacking* ([COUR-SERA, 2025b](#)). Essa ferramenta foi utilizada em [Ferro et al. \(2024\)](#).

- ***Frameworks de Árvores de Decisão e Boosting:***

Para modelos de *ensemble* de árvores de decisão e *boosting* (GBDT), foram utilizados nos artigos dois diferentes *frameworks* LightGBM em [Ohana et al. \(2021\)](#) e XGBoost em [Ayatollahi e Jafari \(2025\)](#). Estes *frameworks* são otimizados para o algoritmo GBDT por sua velocidade e alta performance, além de oferecerem vantagens especialmente em problemas de classificação com características de dados. Apesar de serem considerados métodos de *Machine Learning*, são mais adequados para conjuntos de dados pequenos. Além disso, os métodos GBDT têm a capacidade de lidar com conjuntos de dados desbalanceados e permitem um treinamento rápido ao utilizar o crescimento de árvore *leaf-wise* ([OHANA et al., 2021](#)).

2.5 Emergência da Inteligência Artificial Explicável (xAI)

A capacidade de previsão dos modelos de *Deep Learning* e *Ensemble Learning*, apesar de vantajosa, gera uma insegurança no setor financeiro: a falta de transparência e interpretabilidade. Essa característica de *black box* é uma barreira para sua adoção prática, pois faz se necessário a capacidade de auditar e justificar as decisões de investimento ou previsão de risco. A Inteligência Artificial Explicável (xAI) surge como o campo que lida com esse desafio, fornecendo ferramentas para entender como e por que um modelo chegou a um resultado específico.

2.5.1 O SHAP como Ferramenta de Interpretabilidade

A metodologia SHAP (*SHapley Additive exPlanations*), surgiu como a ferramenta dominante para a xAI nos artigos analisados. Sua principal vantagem é a capacidade de fornecer uma atribuição de features consistente e justa, explicando a contribuição de cada variável para a previsão final do modelo. Em contrapartida a avaliação dos métodos de previsão que apenas medem a performance da previsão, vários artigos destacam o papel crescente da Inteligência Artificial Explicável (xAI) como parte essencial da metodologia.

Nos problemas de previsão de crises, a xAI foi essencial para identificar as causas do risco. Em [Ohana et al. \(2021\)](#) foi utilizado o SHAP para identificação das variáveis mais importantes para o planejamento de crises, além de fornecer uma explicação local da probabilidade de crise em cada data. Em [Ayatollahi e Jafari \(2025\)](#) também foi utilizado o SHAP, porém para previsão de modelo GBDT, o XGBoost, na previsão de *crashes*. Isso evidenciou a importância de se auditar a decisão de modelos de previsão além dos de redes neurais.

Mesmo em modelos de *Deep Learning* (DL) para previsão de valor (regressão), o SHAP foi aplicado para entender as suas previsões e obter uma maior transparência, interpretabilidade e aceitação em aplicações financeiras. Em [Gupta et al. \(2025\)](#) Redes LSTM foram integradas ao SHAP para tentar suprir essa carência, ao explicar a contribuição temporal de cada *time-step* na previsão do preço de fechamento. Por meio dessa integração SHAP com o LSTM, foi possível entregar previsões precisas, e também obter *insights* sobre quais características temporais impulsionam o comportamento do mercado.

3 Metodologia

Este capítulo estabelece a estrutura e as técnicas empregadas para desenvolver e validar o modelo de previsão, garantindo a replicabilidade e a solidez científica do projeto. A metodologia espelha o fluxo de trabalho, está organizada de forma sequencial e detalha as etapas desde a aquisição e o pré-processamento dos dados, a modelagem, o treinamento, os objetivos e métricas de desempenho, as arquiteturas de *Deep Learning*, as formas de avaliação e a utilização de métodos de Interpretabilidade (xAI).

3.1 Escopo do Projeto

O escopo do projeto é definido pelo objetivo de transformar dados históricos de preço e indicadores de mercado em previsões acionáveis para o período futuro. A estratégia adotada utiliza a LSTM como modelo baseline para conduzir uma avaliação sistemática de diferentes abordagens de pré-processamento, engenharia de *features* e representações de *input*. Por meio de um *ablation study*, o melhor *pipeline* identificado é aplicado em arquiteturas de *Deep Learning* SOTA (xLSTM-TS e Transformer-TS), visando verificar se modelos mais complexos conseguem extrapolar o desempenho da baseline e obter previsões direcionais mais precisas para o índice S&P 500. A Fig. 6 ilustra o fluxo de trabalho e orienta a organização das seções seguintes.

- **Aquisição de Dados:** Coleta de preços históricos e volume do S&P 500 (2000–2024).
- **Pré-processamento e Features:** Tratamento de dados, definição de *features* e *target* direcional.
- **Ablation Study (LSTM Baseline):** Teste de seis variantes de *input* e normalização; avaliação via MCC, Acurácia, F1, AUC-ROC.
- **Modelos SOTA:** Aplicação do pré-processamento definido de acordo com o *ablation study* nos modelos xLSTM-TS e Transformer-TS (regressão com direção derivada).
- **Avaliação:** Métricas de regressão (RMSE, MAPE, R^2).
- **Interpretabilidade (xAI):** Aplicação do SHAP para explicar contribuições de *features* e *time steps*.




Figura 6 – Fluxo de Projeto (Fonte: Autor)

3.2 Aquisição de Dados

Esta seção apresenta as informações referentes ao conjunto de dados utilizado no estudo, incluindo as fontes de informação, o período de observação considerado e as variáveis (*features*) empregadas como entradas para a modelagem preditiva. O foco deste trabalho é o mercado acionário norte-americano, escolhido em razão de sua elevada liquidez e relativa estabilidade quando comparado ao mercado brasileiro. Para a validação do modelo proposto, será utilizado como referência o Índice S&P 500, indicador de desempenho do mercado de ações dos Estados Unidos.

Os dados históricos serão coletados via Yahoo Finance com granularidade diária, cobrindo o período de 03 de janeiro de 2000 a 30 de dezembro de 2024, totalizando 6.288 dias úteis. O *dataset* inclui as variáveis (*features*) padrão de negociação (OHLC) e volume, base das análises técnicas.

3.3 Pré-processamento de Dados

A fase de pré-processamento é essencial para transformar a série temporal despadronizada em um formato estruturado, capaz de maximizar a capacidade de aprendizado dos modelos de previsão. Esta etapa prioriza a escalabilidade dos dados e a criação de uma estrutura temporal que evite o vazamento de informações futuras. As escolhas a seguir foram realizadas em estudos como o de [Gupta et al. \(2025\)](#), que demonstram a eficácia dessa abordagem em contextos semelhantes de previsão de séries temporais financeiras.

- **Tratamento de Ruído:**

Antes de construir qualquer *feature*, os dados brutos foram inspecionados para garantir sua integridade. A série do S&P 500 (2000–2024) não apresentou valores faltantes nas colunas de preço (OHLC). O único problema identificado foram dias com volume zero, que foram tratados como ausentes e imputados pela mediana móvel dos dias anteriores. Além disso, foi definido que o preço de referência utilizado em todo o projeto seria o *Close* (preço de fechamento bruto), em vez do *Adj Close* (preço de fechamento ajustado), por ser o valor bruto de mercado sem ajustes retroativos que poderiam introduzir viés temporal.

- **Engenharia de *Features*:**

Os preços brutos (OHLCV) não são diretamente adequados como entrada para redes neurais em séries temporais financeiras. O preço absoluto do S&P 500 cresceu de ≈ 1.400 USD em 2000 para ≈ 6.000 USD em 2024, o que significa que os valores do conjunto de teste estão muito fora da escala do treino. Para contornar isso, as *features* foram construídas como quantidades relativas e adimensionais derivadas do

preço e do volume, que descrevem o comportamento do mercado em vez do seu nível absoluto.

As 18 *features* utilizadas podem ser agrupadas em quatro categorias e estão detalhadas a seguir:

- **Log-retornos e defasagens** (7 *features*): o log-retorno diário atual ($\log(P_t/P_{t-1})$) mede a variação percentual do preço de forma simétrica e estacionária (Preço P_t é o *Close* do dia t). As defasagens de 1, 2, 3, 5, 10 e 20 dias fornecem ao modelo memória sobre os movimentos recentes do mercado, totalizando 7 *features* de retorno.
- **Tendência relativa** (3 *features*): razões entre o preço atual e as médias móveis de 5 e 20 dias ($P_t/\bar{P}_5$, $P_t/\bar{P}_{20}$, $\bar{P}_5/\bar{P}_{20}$). A média móvel $\bar{P}_k$ é calculada como a média dos preços de fechamento dos últimos k dias. Essas razões indicam se o mercado está acima ou abaixo da sua tendência de curto e médio prazo.
- **Volatilidade realizada** (2 *features*): desvio padrão dos log-retornos em janelas de 20 e 60 dias, calculado como $\sigma_k = \sqrt{\frac{1}{k} \sum_{i=0}^{k-1} (\logret_{t-i} - \overline{\logret})^2}$, onde $\logret_{t-i} = \log(P_{t-i}/P_{t-i-1})$. Capturam o regime de risco do mercado: período calmo x período de alta incerteza.
- **Volume e amplitude** (6 *features*): as seis *features* deste grupo são calculadas da seguinte forma: (i) volume em escala logarítmica, definido como $\log(V_t)$ onde V_t é o volume negociado no dia t ; (ii) volume normalizado pela média de 20 dias, calculado como $V_t/\bar{V}_{20}$, onde $\bar{V}_{20}$ é a média dos volumes dos últimos 20 dias; (iii) amplitude intradiária, dada por $H_t - L_t$, sendo H_t o preço máximo e L_t o preço mínimo do dia t ; (iv) retorno absoluto, definido como $|P_t - P_{t-1}|$; (v) retorno quadrático, calculado como $(P_t - P_{t-1})^2$; e (vi) RSI de 14 períodos, índice de força relativa calculado como $RSI_t = 100 - \frac{100}{1 + RS_t}$, onde $RS_t = \frac{\bar{G}_{14}}{\bar{L}_{14}}$ é a razão entre a média dos ganhos ($\bar{G}_{14}$) e a média das perdas ($\bar{L}_{14}$) dos últimos 14 dias. O RSI varia de 0 a 100, com valores acima de 70 indicando sobrecompra e abaixo de 30 indicando sobrevenda. Essas *features* refletem a intensidade das negociações e o momentum do mercado.

O *target* é a variável que o modelo precisa prever, funcionando como a resposta correta que o algoritmo deve aprender a identificar. Para cada dia t , o *target* y_{t+1} indica a direção do preço no dia seguinte: 1 se o preço subir, 0 se cair. O *target* é sempre calculado a partir do preço *Close* original, sem aplicar nenhum pré-processamento (como DWT ou normalização). Isso evita vazamento de informação: o rótulo de saída permanece puro e independente das transformações aplicadas às *features* de entrada.

- **Ablation Study** — Variantes de Normalização e *Input*:

Para identificar a representação de *input* e a normalização mais adequadas para os modelos de previsão, foram definidas seis variantes que cobrem sistematicamente três eixos de decisão: (i) tipo de *input* do preço; (ii) aplicação ou não de *denoising* wavelet; e (iii) técnica de normalização. Todos os parâmetros de normalização e limiares de *denoising* são ajustados exclusivamente nos dados de treino, garantindo que nenhuma informação do conjunto de validação ou teste influencie o pré-processamento. A Tab. 4 apresenta as seis variantes testadas e as motivações de cada uma.

Tabela 4 – Variantes do *Ablation Study* de Pré-processamento

Variante	<i>Input</i>	Normalização	Motivação
A	<i>Close</i> bruto	Z-score	<i>Baseline</i> padrão da literatura. As 18 <i>features</i> são calculadas a partir do <i>Close</i> original, normalizado por média e desvio padrão do treino. Ponto de referência mínimo.
B	<i>Close</i> DWT	Z-score	Aplica <i>denoising</i> wavelet (DWT) no <i>Close</i> antes de calcular as 18 <i>features</i> e o Z-score. Avalia se remover o ruído de alta frequência do preço melhora a aprendizagem do modelo.
C	Log-retornos	Z-score	Substitui o <i>Close</i> pelo log-retorno diário como base para calcular as 18 <i>features</i> . Avalia a previsão do modelo de uma a série estacionária e adimensional.
D	Log-ret. DWT	Z-score	Aplica DWT nos log-returns antes de calcular as 18 <i>features</i> . Combina a estacionarização via log-retorno com o <i>denoising</i> wavelet. Avalia se ambas as transformações juntas são complementares.
E	<i>Close</i> bruto	Min-Max	As 18 <i>features</i> são calculadas a partir do <i>Close</i> original, normalizado para o intervalo $[0, 1]$. Testa a sensibilidade do modelo a uma normalização que depende dos valores extremos do treino.
F	<i>Close</i> DWT	Min-Max	Aplica DWT no <i>Close</i> antes de calcular as 18 <i>features</i> e a normalização Min-Max. Combina o <i>denoising</i> wavelet com a normalização Min-Max.

- **Divisão Temporal:**

A divisão foi feita de forma estritamente temporal, sem embaralhamento, para simular condições reais de implantação. O modelo utiliza uma janela deslizante de 20 dias (*lookback*) para prever a direção do preço no dia seguinte (*timestep* $t + 1$):

- **Treino:** 2000–2020 (≈ 5.275 dias, 84%) — inclui crises de 2008 e COVID-2020, permitindo ao modelo aprender múltiplos regimes econômicos.
- **Validação:** 2021–2022 (≈ 503 dias, 8%) — monitoramento do *early stopping* e ajuste de hiperparâmetros.
- **Teste:** 2023–2024 (≈ 503 dias, 8%) — regime de juros altos pós-pandemia, contexto macroeconômico inédito para o modelo.

A validação cruzada K-Fold foi descartada por ser inadequada para séries temporais: na divisão aleatória, dados futuros inevitavelmente aparecem no treino, gerando métricas artificialmente otimistas.

3.4 Modelagem e Arquitetura

Foram implementados três modelos de *Deep Learning* com diferentes abordagens de previsão. A LSTM foi utilizada como *baseline* para o *ablation study*; os modelos SOTA xLSTM-TS e Transformer-TS foram treinados com o pré-processamento definido de acordo com o *ablation study*, permitindo uma comparação estruturada entre arquiteturas de complexidade crescente.

- **LSTM (Classificação Binária Direta):**

A LSTM foi implementada com Keras/TensorFlow como classificador binário e utilizada como *baseline* para o *ablation study* por possuir tempo de processamento bem inferior às demais arquiteturas. O modelo consiste em uma camada LSTM unidirecional com 32 unidades, *dropout* de 0,1 e uma camada densa de saída com ativação sigmoide que produz $P(sobe) \in [0, 1]$. A função de perda é a Entropia Cruzada Binária (*Binary Crossentropy*) e o otimizador é o Adam com taxa de aprendizado padrão, *batch size* de 32 e até 100 épocas. O *input* são as 18 *features* técnicas sobre uma janela de 20 dias (*lookback*). O treinamento utiliza *early stopping* com paciência de 10 épocas, monitorando a perda de validação e restaurando os melhores pesos.

- **xLSTM-TS (Regressão com Direção Derivada):**

O xLSTM-TS [Gil, Duhamel-Seblin e McCarren \(2024\)](#) foi implementado em PyTorch a partir do repositório oficial, com as seguintes adaptações para este trabalho: (i) substituição do *backend* CUDA pelo *backend vanilla* para execução em CPU; (ii) redução do *input* para uma única *feature* (*Close* denoised), em vez das múltiplas séries utilizadas no repositório original; (iii) escalonamento Min-Max ajustado exclusivamente nos dados de treino, evitando vazamento de informação. O pré-processamento aplicado foi: *denoising* DWT causal (*db4*, *mode='zero'*, limiar calculado no treino) seguido de normalização Min-Max, com janela de entrada (*look-back*) de 150 dias. Os demais hiperparâmetros do artigo original foram preservados: 4 blocos xLSTM, *embedding* de dimensão 64, 2 cabeças de atenção, *batch size* 16, taxa de aprendizado 10^{-4} , agendamento *ReduceLROnPlateau* e *early stopping* com paciência de 40 épocas. O modelo é treinado para regressão do preço absoluto (perda MSE) e a direção prevista é derivada em pós-processamento pela diferença entre previsões consecutivas.

- **Transformer-TS (Regressão com Direção Derivada):**

O Transformer-TS foi implementado em PyTorch a partir da arquitetura proposta por Vaswani et al. (2017), com adaptações para regressão de séries temporais univariadas: utilizou-se apenas o bloco codificador (sem o decodificador original) e adicionou-se uma cabeça de regressão sobre o último passo temporal. A arquitetura resultante consiste em projeção de entrada $\text{Linear}(1 \rightarrow 64)$, *positional embedding* aprendido, 2 blocos *TransformerEncoderLayer* com atenção de 4 cabeças e FFN de dimensão 256, totalizando ≈ 113.921 parâmetros treináveis. O pré-processamento e todos os hiperparâmetros de treino foram alinhados aos do xLSTM-TS (mesma perda MSE, otimizador, *scheduler*, *early stopping* e *lookback* de 150 dias), garantindo comparação direta entre as duas arquiteturas.

Neste trabalho, o Transformer-TS e o xLSTM-TS são comparados sob condições idênticas de treinamento, permitindo avaliar o ganho marginal de cada arquitetura SOTA em relação à LSTM *baseline*.

3.5 Objetivo das Previsões

O objetivo principal dos três modelos é a **classificação direcional**: para cada dia t do conjunto de teste, prever se o preço de fechamento do dia $t + 1$ será maior (classe 1 — sobe) ou menor (classe 0 — desce). A LSTM realiza essa tarefa diretamente como classificador; o xLSTM-TS e o Transformer-TS a realizam indiretamente, por meio de regressão de preço e derivação da direção pela diferença consecutiva.

As métricas utilizadas foram selecionadas para cobrir diferentes aspectos da avaliação e desempenho:

- **MCC (*Matthews Correlation Coefficient*)**: adotado como métrica principal por ser robusto ao desbalanceamento natural do mercado (que sobe em $\approx 55\%$ dos dias), evitando que um modelo que “chuta sempre sobe” aparente bom desempenho.
- **Acurácia, F1-Score e AUC-ROC**: métricas complementares de classificação que permitem comparar os modelos sob diferentes perspectivas e facilitar o diálogo com a literatura.
- **Teste de McNemar**: teste estatístico que verifica se o desempenho observado é significativamente superior ao de um classificador trivial, conferindo rigor à comparação entre variantes.
- **RMSE, MAPE e R^2** : aplicados ao xLSTM-TS e Transformer-TS para avaliar a qualidade da regressão de preço absoluto em complemento à análise direcional.

3.6 Estratégia de Interpretabilidade (xAI)

A última etapa da metodologia consiste em aplicar o SHAP aos modelos treinados, garantindo transparência e auditabilidade das previsões. O SHAP é aplicado sobre o conjunto de teste fornecendo explicações locais (por previsão individual) e globais (importância média por *feature*). O foco da análise é:

- **Contribuição Temporal dos *Time Steps*:** o SHAP mede a contribuição de cada dia do histórico de entrada para a previsão final. Isso permite identificar quais períodos da “memória” da rede foram mais determinantes para a decisão do modelo.
- **Identificação de Variáveis Chave:** o SHAP indica quais *features* técnicas (log-retornos, médias móveis, RSI, volatilidade, volume) mais contribuem para as previsões direcionais, fornecendo *insights* interpretáveis sobre os padrões aprendidos pelos modelos.

4 Cronograma

Este capítulo apresenta o cronograma de atividades planejadas para a execução do projeto, organizadas de acordo com as etapas definidas na metodologia. O cronograma está estruturado para um semestre letivo, considerando aproximadamente 16 semanas de execução. A Tabela 5 apresenta a distribuição das atividades ao longo das semanas do semestre. Elas estão organizadas em etapas, e seguiu como base o fluxo de trabalho estabelecido na metodologia. Algumas etapas foram divididas para maior clareza e tranquilidade na realização de tarefas mais complexas e que exigiam mais tempo e complexidade:

Tabela 5 – Cronograma de Atividades do TCC 2

Atividade	S1	S2	S3	S4	S5	S6	S7	S8	S9	S10	S11	S12	S13	S14	S15	S16
Aquisição de Dados	•	•														
Pré-processamento		•	•	•												
Modelagem				•	•	•										
Treinamento						•	•	•								
Avaliação e Validação								•	•	•	•	•				
Interpretabilidade (xAI)											•	•	•	•		
Escrita do Relatório					•	•	•	•	•	•	•	•	•	•		
Revisão e Ajustes														•	•	•

1. **Aquisição de Dados:** Coleta dos dados históricos do IBOVESPA via Yahoo Finance e verificação da integridade do *dataset*.
2. **Pré-processamento:** Tratamento de ruídos, normalização MinMax, aplicação da técnica de *Sliding Window* (janela de 100 dias) e divisão dos dados (65% treino / 35% teste).
3. **Modelagem e Treinamento:** Implementação da arquitetura *Stacked LSTM* utilizando Keras/TensorFlow, configuração dos hiperparâmetros e treinamento do modelo com validação cruzada sequencial.
4. **Avaliação e Validação:** Geração de previsões no conjunto de teste e avaliação do desempenho utilizando métricas de regressão (RMSE, R^2 Score) e análise de rentabilidade financeira.
5. **Interpretabilidade (xAI):** Aplicação do SHAP para análise da contribuição temporal dos *time steps* e identificação das variáveis chave nas previsões.
6. **Documentação:** Redação do relatório final, ajustes e preparação da apresentação e defesa do trabalho.

Referências

AYATOLLAHI, M.; JAFARI, S. M. Explainable artificial intelligence (xai) in predicting stock market crashes: A case study of the tehran stock exchange. *ResearchGate Preprint*, june 2025. Disponível em: <<https://www.researchgate.net/publication/392512200>>. Citado 7 vezes nas páginas 11, 25, 27, 29, 30, 31 e 32.

CAPITAL, C. *OHLIC: descubra o que é, como interpretar e aplicar na análise técnica*. 2025. Disponível em: <<https://cmcapital.com.br/blog/ohlc/>>. Acesso em: 02 de dez. de 2025. Citado na página 18.

COURSERA. *TensorFlow vs. Keras: What's the Difference?* 2025. Disponível em: <<https://www.coursera.org/articles/tensor-flow-vs-keras>>. Acesso em: 19 de nov. de 2025. Citado 2 vezes nas páginas 12 e 30.

COURSERA. *What Is Scikit-Learn?* 2025. Disponível em: <<https://www.coursera.org/articles/what-is-scikit-learn>>. Acesso em: 19 de nov. de 2025. Citado na página 31.

DAMETTO, R. C. Estudo da aplicação de redes neurais artificiais para predição de séries temporais financeiras. Universidade Estadual Paulista (Unesp), Bauru - SP, 2018. Citado 6 vezes nas páginas 12, 13, 25, 26, 30 e 31.

datacamp. *Perceptrons multicamadas em aprendizado de máquina: Um guia abrangente*. 2024. Disponível em: <<https://www.datacamp.com/pt/tutorial/multilayer-perceptrons-in-machine-learning>>. Acesso em: 29 de out. de 2025. Citado na página 21.

FERRO, J. V. R. et al. Uma avaliação sistemática de técnicas de aprendizado de máquina baseadas em ensemble para previsão de índices do mercado de ações usando séries temporais financeiras. Universidade Federal de Alagoas, Maceió - AL, 2024. Citado 12 vezes nas páginas 11, 12, 13, 16, 20, 21, 25, 26, 27, 28, 30 e 31.

FINANCE Yahoo. *IBOVESPA (BVSP)*. 2025. Disponível em: <<https://finance.yahoo.com/quote/%5EBVSP/history/>>. Acesso em: 19 de nov. de 2025. Citado 3 vezes nas páginas 7, 16 e 17.

FINANCE Yahoo. *IBOVESPA (BVSP)*. 2025. Disponível em: <<https://finance.yahoo.com/quote/%5EBVSP/chart/>>. Acesso em: 01 de dez. de 2025. Citado 2 vezes nas páginas 7 e 28.

FINANCE Yahoo. *S&P 500 (GSPC)*. 2026. Disponível em: <<https://finance.yahoo.com/quote/%5EGSPC/history/>>. Acesso em: 24 de jun. de 2026. Citado 2 vezes nas páginas 7 e 17.

GIACOMEL, F. d. S. Um método algorítmico para operações na bolsa de valores baseado em ensembles de redes neurais para modelar e prever os movimentos dos mercados de ações. Universidade Federal do Rio Grande do Sul (UFRGS), Porto Alegre - RS, 2016. Citado 6 vezes nas páginas 21, 23, 25, 27, 28 e 30.

- GIL, G. L.; DUHAMEL-SEBLINE, P.; MCCARREN, A. *An Evaluation of Deep Learning Models for Stock Market Trend Prediction*. 2024. Disponível em: <<https://arxiv.org/abs/2408.12408>>. Acesso em: 24 de jun. de 2026. Citado 3 vezes nas páginas 23, 31 e 38.
- GUNAY Deniz. *CART*. 2023. Disponível em: <<https://medium.com/@denizgunay/cart-4838fec3e405>>. Acesso em: 29 de out. de 2025. Citado na página 21.
- GUPTA, Y. et al. An interpretable framework for stock market forecasting using long short-term memory (lstm) networks with shap-explainable ai (xai) method. In: IEEE. *2025 6th International Conference on Data Intelligence and Cognitive Informatics (ICDICI)*. [S.l.], 2025. p. 539–546. Citado 9 vezes nas páginas 11, 12, 13, 25, 26, 30, 31, 32 e 35.
- INVESTOPEDIA. *Stock Volume Explained: Key Insights for Market Trends and Liquidity*. 2025. Disponível em: <<https://www.investopedia.com/terms/v/volume.asp>>. Acesso em: 02 de dez. de 2025. Citado na página 18.
- INVESTOPEDIA. *Understanding Adjusted Closing Price Definition, Benefits & Criticisms*. 2025. Disponível em: <https://www.investopedia.com/terms/a/adjusted_closing_price.asp>. Acesso em: 02 de dez. de 2025. Citado na página 18.
- NELSON, D. M. Q. Uso de redes neurais recorrentes para previsão de séries temporais financeiras. Universidade Federal de Minas Gerais, Belo Horizonte - MG, 2017. Citado 7 vezes nas páginas 11, 12, 21, 25, 27, 30 e 31.
- NIMBUS Monolito. *Machine Learning de Séries Temporais LSTM*. 2018. Disponível em: <<https://www.monolitonimbus.com.br/machine-learning-de-series-temporais-lstm/>>. Acesso em: 30 de out. de 2025. Citado na página 21.
- OHANA, J. J. et al. Explainable ai (xai) models applied to the multi-agent environment of financial markets. In: SPRINGER. *International Workshop on Explainable, Transparent Autonomous Agents and Multi-Agent Systems*. [S.l.], 2021. p. 189–207. Citado 8 vezes nas páginas 13, 24, 25, 27, 29, 30, 31 e 32.
- PURWAR Parul. *How we cut CatBoost Inference Latency by 60x with C++ and Go*. 2025. Disponível em: <<https://medium.com/shiprocket-ai/how-we-cut-catboost-inference-latency-by-60x-with-c-and-go-54b163f22963>>. Acesso em: 29 de nov. de 2025. Citado na página 12.
- SCIENCE Super Data. *Modelos de Master Ensemble: Bagging vs Boosting em Machine Learning EXPLICADO*. 2020. Disponível em: <<https://www.youtube.com/watch?v=ZFXD6lxm3nE&t=337s>>. Acesso em: 01 de dez. de 2025. Citado 2 vezes nas páginas 7 e 24.
- SETHI Alakh. *Support Vector Regression Tutorial for Machine Learning*. 2025. Disponível em: <<https://www.analyticsvidhya.com/blog/2020/03/support-vector-regression-tutorial-for-machine-learning/>>. Acesso em: 29 de out. de 2025. Citado na página 20.

TECH Didatica. *Métodos Ensemble*. 2024. Disponível em: <<https://didatica.tech/metodos-ensemble/>>. Acesso em: 30 de out. de 2025. Citado na página 23.

VASWANI, A. et al. Attention Is All You Need. In: *Advances in Neural Information Processing Systems*. [S.l.: s.n.], 2017. v. 30. Citado 2 vezes nas páginas 23 e 39.

XP. *Análise Fundamentalista x Análise Técnica: Entenda as diferenças entre os métodos para investir na Bolsa*. 2024. Disponível em: <<https://conteudos.xpi.com.br/aprenda-a-investir/relatorios/analise-fundamentalista-x-analise-tecnica-entenda-diferencas/>>. Acesso em: 19 de nov. de 2025. Citado na página 20.

YEHIA Nora. *Understanding Long Short Term Memory Networks*. 2024. Disponível em: <<https://mlarchive.com/deep-learning/understanding-long-short-term-memory-networks/>>. Acesso em: 01 de dez. de 2025. Citado 2 vezes nas páginas 7 e 22.